文章编号: 1000 - 2995(2024)02 - 011 - 0001 DOI: 10.19571/j.cnki.1000 - 2995.2024.02.001

基于深度学习的我国科技政策属性识别

李牧南[1,2], 王 良[1], 赖华鹏[1]

(1. 华南理工大学 工商管理学院, 广东 广州 510641;
2. 广东省创新方法与决策管理系统重点实验室, 广东 广州 510641)

摘要: 当前基于深度学习算法的文本分析更多聚焦于微博、评论和新闻头条为代表的舆情监测和情感分析等短文本信息处理, 而针对各类政策文本、论文和专利全文的属性识别和长文本分类等相关研究较少, 存在一定拓展空间。与传统的机器学习模型相比, 深度学习在自然语言处理和文本特征提取方面具有显著优势, 其可通过预训练语言模型降低特征工程的人工干预, 从而在政策属性和政策工具识别等领域具有较好的应用前景。本文针对我国科技政策属性(引导型、强制型和鼓励型)的自动识别问题, 导入当前流行的几种深度学习模型进行了对比分析。与此同时, 本文还针对政策文本的取词长度、数据增强和文本信息量估算等关联计算问题也进行了理论解析, 从而进一步丰富了深度学习模型在科学计量, 尤其是科技政策文本分析领域的应用。理论和实证分析结果显示, 经过基于 EDA(Easy Data Augmentation)方法的文本数据增强之后, 当前几种代表性的深度学习模型在面向较为抽象的科技政策属性识别问题上均显著提升了处理能力, 其中 EDA + Bi - LSTM - Attention 的识别准确率超过 88%, 其他参与实验的深度学习模型(TextCNN、Bi - LSTM、RCNN、CapsNet 和 FastText 等)在文本增强之后的平均识别率也超过了 80%; 但是, 文本取词长度从 500 词增加到 2000 词对中文科技政策属性识别的效果提升不显著。本文的研究对于科技政策属性自动识别、中文长文本分类和政策工具识别等科技管理相关量化分析具有一定的启示意义和参考价值。

关键词: 深度学习; 科技政策; 属性识别; 数据增强; 文本分类

中图分类号: F124.3 **文献标识码:** A

0 引言

2015 年前后, 谷歌公司基于深度神经网络研制的 AlphaGo 在正式比赛中击败职业围棋九段选手, 极大推动了深度学习相关理论、算法和模型的发展[1-2]。随着计算硬件技术发展, 深度学习模型开始逐渐覆盖到传统机器学习应用领域, 其中包括: 医疗影像处理、自然语言理解和机器翻译等, 且在多个相关领域表现出较好的处理能力和效果[3-4]。近年来, 深度学习也逐步在人文社科领域得到一定程度应用, 例如, 王超[5]将深度学习模型应用到行业指数预测, Gunnarsson 等[6]针对传统的信用欺诈问题, 提出了一种基于深度学习的解决方案, 而 Lehrer 等[7]则将深度学习应用到社交媒体文本的情感分析, 并取得较好效果。2018 年以来, 基于深度学习模型的文本分类(text classification)和文本情感分析(text sentiment - analysis)逐渐成为文本挖掘领域的研究前沿之一[8-9]。例如, 张海涛等[10]将卷积神经网络应用的微博文本的情感分析领域; Guo 等[11]基于多通道 TextCNN 模型, 结合词嵌入方法进一步改进了短文本的分类效果; 吴鹏等[12]在网民负面情感分析中, 比较了支撑向量机(Support Vector Machine, SVM), 卷积神经网络(Convolutional Neural Network, CNN)和长短期记忆网络(Long short - Term Memory, LSTM)几类模型, 并发现双向长短期记忆网络(Bi - LSTM)的分类效果更好。在深度学习模型提出之前, 无论是朴素贝叶斯, 决策树和支撑向量机等统计学习模型, 还是其他启发式计

收稿日期: 2022 - 08 - 09; 修回日期: 2023 - 03 - 13.
基金项目: 国家自然科学基金面上项目"基于多源数据融合与机器学习的新兴技术风险挖掘研究"(72074081, 2021.01—2024.12); 国家社会科学基金重点项目"加快我国科技自立自强发展战略问题研究"(22AZD035, 2022.05—2025.12)。
作者简介: 李牧南(1974—), 男(汉), 江西庐山人, 华南理工大学工商管理学院教授, 博士生导师, 研究方向: 科技与创新管理。
王 良(1996—), 男(汉), 安徽芜湖人, 华南理工大学工商管理学院博士研究生, 研究方向: 信息管理与信息系统。
赖华鹏(1998—), 男(汉), 江西赣州人, 华南理工大学工商管理学院硕士研究生, 研究方向: 信息管理与信息系统。
通信作者: 王良

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

算模型都经常应用到文本分类[13]；但传统的机器学习方法(统计学习或启发式计算)受限于模型和算法自身的计算能力，对于一些颗粒较大的非结构化数据(例如：政策文本、论文和专利全文等)存在一定的处理挑战[14]。由于深度学习模型可以处理较深层的语义上下文(semantic context)，相较传统机器学习算法，对于长文本数据具有一定的优势；因此，近年基于深度学习的文本挖掘也逐渐成为信息管理和科学计量领域研究热点之一[15]。与英语为代表的字母表音体系相比，中文自然语言处理更为复杂，导致针对中文政策属性识别、文本分类、主题聚类和语义分析处理更为困难[16-17]。随着深度学习模型在长文本分类领域的应用，针对政策文本的属性识别和政策工具的自动发现也逐渐成为科技管理的研究热点之一[18-20]。

从目前深度学习在文本挖掘领域的主流研究文献看，大致可以分为两大类：一是面向海量短文本(在线评论、微博、推特和脸书等)的数据挖掘，具体应用有商品推荐、大数据营销和社会舆情分析等[21-22]；二是面向大文本或长文本数据的分类、语义和主题挖掘。传统机器学习模型在针对政策文本为代表的长文本数据时，一般需要在领域专家知识和经验基础上，结合摘要和关键词提取形成专属特征集，存在一定的泛化困境；而深度学习算法可以在通用的语言模型基础上，直接将海量文本数据导入到深度神经网络进行自学习和特征提取(超参数训练)，并完成相关的文本挖掘[23]。从当前深度学习与文本挖掘相结合的研究现状看，面向短文本的应用相对更为成熟和广泛，但对于中文长文本的分类和内容挖掘而言，无论是相关深度学习算法的精度，还是相关模型的超参数优化，以及专用语料库构建等方面都存在一定的研究拓展空间。

在基于机器学习的语音情感分析和自然语言处理领域，在样本数据不太丰富或者图像和音频等多媒体数据存在一定噪声情况下，数据增强技术逐渐引起学术界的关注，且在一些具体的应用场景(例如：医疗影像处理和动作捕捉等)取得了较好效果[24-25]。对于深度学习算法而言，考虑到学习样本规模对于深度神经网络的训练效果影响较为显著，张一珂等[26]针对语音识别的有限样本问题，提出了基于最大似然估计的语言模型数据增强方法，有效改进了特定情境下的语音识别准确率；而李茜茜等[27]则提出了时频域的数据增强方法，对原有语音数据集进行扩充，并在多个机器学习算法上进行了验证，取得不错效果。陆垚杰等[28]针对事件检测标注数据的规模和训练阶段的不稳定性，提出了基于语言学扰动的数据增强方法，从语法和语义两个角度提升事件检测的性能。而针对在自然语言处理领域中高质量的标签数据较难获取的问题，刘彤等[29]采用简单数据增强和反向翻译的文本增强技术获取大量无标签数据，部分提高了在情感分析公开数据集上的预测稳定性。2019 年，Wei 和 Zou[30]提出了一种 EDA(Easy Data augmentation)方法，是一种轻量级的文本数据增强技术。对于仅需克服小样本学习弱点，适当增加文本数据规模的应用场景而言，EDA 方法可以输出规模递增的同语义样本。从算法原理看，EDA 是一种轻型数据扩充和增强方法，可用于各类文本数据扩充，以及根据现有文本生成语义相似特征的数据扩张。

科技(创新)政策的属性识别和政策工具挖掘已经成为近年科技政策计量研究领域的热点问题之一。Ekboir[31]认为科技政策属性从政府资助角度可以区分为：直接投资、间接支持和外围刺激。Morosini[32]从知识整合角度认为国家或区域科技政策可以划分为任务导向和扩散导向两种类型。Onishi[33]则提出科技政策属性可以根据创新的不同阶段予以区分。张永安等[34]则提出区域科技创新政策属性可以归结为强制型和引导型两种，其中强制属性的科技政策作用强度大，但其政策工具的丰富性有限，而引导型政策在政策工具组合方面更为灵活。张宝建等[35]进一步丰富了政策编码和文本聚类分析方法，认为我国科技政策属性可以进一步区分为强制、引导和鼓励三种类型。针对政策属性的自动识别，陈玲和段尧清[36]基于 TF-IDF 算法和 LDA 模型对我国政府的数据开放政策进行了量化分析；杨锐等[37]基于卷积神经网络模型对于我国能源政策文本特征进行了自动识别分析，且识别效果较好。

政策文本属于一种特殊的文本数据类型，主要在于政策文本属于政府公文，与一般意义的法律法规文本存在一定差异，且文本长度波动幅度较大；此外，不同政策领域的文本格式、术语和行文规范也存在差异，因此需考虑如何选取适当的取词长度。随着基于深度学习的语言表示和文本分类技术发展，各种集成和改进的深度学习模型也逐渐应用到政策文本分类和工具属性识别领域，其中 LSTM 和注意力机制(Attention Mechanism)模型在中文文本处理领域近年得到广泛关注。例如，黄水清和王东波[38]在处理中文分词时应用了 LSTM 的条件随机场模型，在新时代人民日报语料库构建过程中取得较好效果；王昊等[39]将 LSTM-CRFs 模型应用到情报学理论与方法术语识别领域，进一步增强了复杂实体的术语识别能力；胡吉明等[19]以 LDA 主题模型、注意力机制和 LSTM 为核心，构建了政策文本表示和分类框架，提升了政策文本分类效果。Huang 等[40]面向文本分类提出一种利用层次化多注意力机制的深度神经网络方法，从“词-句”和“句子-文档”两个层次对文档进行描述，提升了基于深度学习的文本分类效果。Zheng 和 Chen[41]则将注意力机制与 Bi-LSTM 模型相结合，即构建 Bi-LSTM+Attention 算法应用到生物医学图像分类领域，也取得较好的应用效果。

综合当前政策属性识别和政策文本挖掘研究现状，深度学习模型在预训练和语言表示方面具有一定优势，并且对特征工程依赖度低，具有更好的泛化能力。此外，在中文自然语言处理领域，LSTM 与其他算法和模型的组合逐渐成为热点，且在中文自动分词、复杂实体术语识别和政策文本分类等领域都取得了较好应用效果；但是，围绕中文科技政策属性的自动识别，文本信息估算、数据增强和文本取词长度等对深度学习算法的影响还存在一些研究

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

盲点。尽管当前基于深度学习的文本分类(含情感分析) 研究关注度高，也产生了一批有影响力的成果，但依然存在一些科学问题需要进一步深入分析和讨论。

第一，在当前基于深度学习的文本处理研究中，其数据源主要来自微博、在线评论和新闻头条等为代表的短文本，针对中文长文本数据的文本挖掘(例如: 政策文本、电子病历、论文和专利全文等) 研究较少，存在较大应用拓展空间。

第二，传统的数据增强方法(例如上文提到的 EDA 方法) 是否可以应用于政策文本分析，其效果如何，也存在一定的研究盲点和拓展空间。

第三，在科技政策属性自动识别和长文本分类中，文本取词长短对于深度学习模型的影响目前也基本处于研究空白，需要在具体的实证分析中予以校验。

1　研究设计

1.1　基本思路

在近年关于科技政策属性识别研究中，基于政策编码和关键词提取的特征工程，结合传统的文本聚类分析是一种常见范式[35]；由此可见，传统政策属性识别方法比较依赖于主观判别和关键词层面的分类和聚类，无法处理文本语句和段落之间的语义关联。深度学习算法则可以直接将政策文本作为处理对象，通过预训练语言模型将政策文本整体映射到向量空间，并通过深度神经网络实现文本特征的自动识别和匹配。因此，针对上文提出的三个科学问题，本文研究的基本思路如图 1 所示。

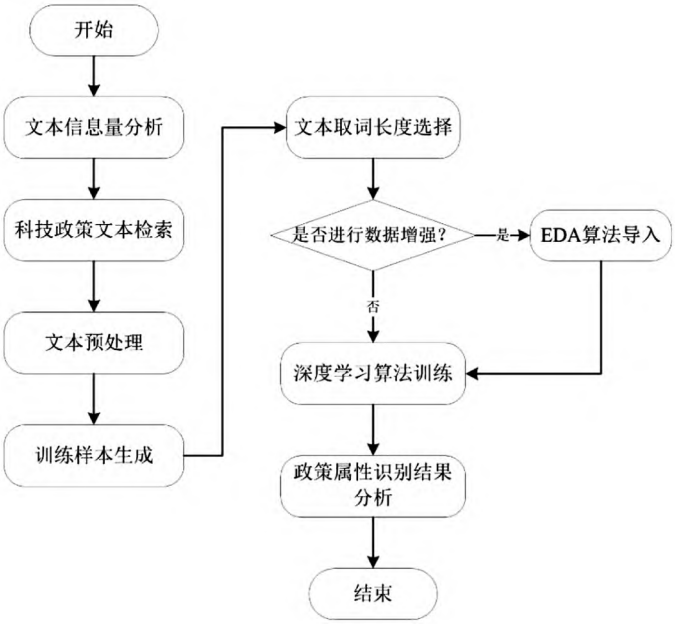

图 1　研究框架图

Figure 1　Research framework diagram

科技政策属性的自动识别可以等价为一个面向特定长文本集合的多分类问题，李娜等[18]发现在中文政策文本分类中，CNN 和 LSTM 均比支撑向量机和逻辑回归模型的分类效果好，且 CNN 总体效能更优，因此，本文以 CNN 作为其他深度学习算法比对的基线模型，而参与对比的深度学习模型包括循环卷积神经网络(Recurrent convolutional neural network，RCNN) 、双向长短期记忆网络(Bi - LSTM) 、引入注意力机制的双向长短期记忆网络(Bi - LSTM - Attention) 和胶囊网络(CapsNet) 等。文献[30]给出了一个面向英语语言的文本增强模型，施国良和陈宇奇[42]将 EDA 与 BERT 模型结合应用到政府部门的问政留言分类领域，取得较好的效果。因此，基于人民日报语料库，本文将提取的科技政策文本采用 EDA 方法进行数据增强，然后利用 Word2vec 模型[43]训练为词向量得到针对政策文本的词向量集合，从而构建出面向政策文本属性自动识别的特定语料库。

1.2　政策文本取词长度与信息量之间的关系

从已有的国内外相关研究看，传统机器学习针对长文本一般都只针对其摘要，或基于人工标签方法进行文本分类处理，较少讨论长文本的取词长短问题; 但全文导入则可能出现词向量矩阵过大和信息冗余问题。在当前基于深度学习的文本分类和文本挖掘研究中，大都基于短文本数据，基本不涉及文本的取词长度问题。但是，取词长度问题对于长文本信息处理比较重要，如果文本长度过长，对全文载入的计算硬件要求较高，也可能出现文本词向量矩阵过大而无法加载的运算问题。鉴于此，本文提出一个

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

关于文本长度与信息量关系的近似测算框架。

定义 1(文本矩阵):假设原文本 $text_i$ 中包含 x_i 个文字,若每个文字表示为一个 n 维向量,则其文本矩阵 W_i 可以表示为公式(1):

$$W_i=\begin{pmatrix} word_1 \\ word_2 \\ \vdots \\ word_{x_i} \end{pmatrix}=\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{x_i1} & a_{x_i2} & \cdots & a_{x_in} \end{pmatrix}_{x_i\times n} \tag{1}$$

假设长文本为了适应分类模型维度一致的要求,需要经过一定的截断处理(例如:BERT 模型只能输入 512 个 token,则实际输入字数更少),且截断长度为 x^*,

(1)若 $x_i\geqslant x^*$,则直接截取文本矩阵的前 x^* 行作为截断后文本矩阵;

(2)若 $x_i<x^*$,则需要在原文本矩阵下方添加 n 维零向量补充至行数为 x^*;

则截断后文本矩阵 W_i^* 可以表示为公式(2):

$$W_i^*=\begin{cases} \begin{pmatrix} word_1 \\ word_2 \\ \vdots \\ word_{x^*} \end{pmatrix}=\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{x^*1} & a_{x^*2} & \cdots & a_{x^*n} \end{pmatrix}_{x^*\times n}, & x_i\geqslant x^* \\ \begin{pmatrix} word_1 \\ word_2 \\ \vdots \\ word_{x_i} \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}=\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{x_i1} & a_{x_i2} & \cdots & a_{x_in} \\ 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{pmatrix}_{x^*\times n}, & x_i<x^* \end{cases} \tag{2}$$

定义 2(文本信息量):假设文本分类中的正常文本均可以起到一定的信息表达作用,且表达作用强度相同,则可以将原文本中所包含的文字个数称为文本数据信息量,也即对于原文本 $text_i$,包含 x_i 个文字,其文本矩阵为 W_i,则其文本数据信息量可以表示为公式(3):

$$Data(W_i)=x_i \tag{3}$$

当文本经过截断长度为 x^* 的截取之后,

(1)若 $x_i\geqslant x^*$,将文本矩阵直接截取,所得到的文本数据信息量即为剩下的文字个数为 x^*,则此时的文本数据信息量可以表示为公式(4):

$$Data(W_i^*)=x^* \tag{4}$$

(2)若 $x_i<x^*$,根据一般意义的信号处理,则需要在原文本矩阵下方补 0,补充 0 的操作在文本分类中会导致文本数据变得稀疏从而降低文本分类效率,所以此处将补充的 0 矩阵称为数据白噪声,此处将数据噪声定义为补充 0 向量的实际个数,也即公式(5):

$$Data(0)=x^*-x_i \tag{5}$$

根据基础的信号处理理论,白噪声越多,则对后续分类效率的负向影响越严重,这里假设噪声系数为 η,则文本数据信息量为公式(6):

$$\begin{aligned} Data(W_i^*)&=Data(W_i)-\eta Data(0) \\ &=x_i-\eta(x^*-x_i) \\ &=(1+\eta)x_i-\eta x^* \end{aligned} \tag{6}$$

1.3 科技政策属性识别的评价指标

考虑到科技政策属性识别可以等价为一个文本多分类问题,本文选取 F_1 值作为模型分类有效性的评价模型,F_1 值的计算公式如式(7)和式(8)所示。

$$\frac{2}{F_1}=\frac{1}{P}+\frac{1}{R} \tag{7}$$

$$F_1=\frac{2PR}{P+R} \tag{8}$$

在公式(7)和(8)中,P 表示精确率,指衡量某个分类的正确率,R 表示召回率,指被正确分类的数量占总数量的比例。

2 实证分析

2.1 数据采集

为尽量保证政策文本数据来源的准确可靠,本文所采集的中文科技政策文本来自北大法宝网①。在进行深度学习算法的对比实验之前,本文对采集到的中文科技政策文本进行预处理,其中包括:剔除掉出现重复的政策文本以及与科技政策无关的文本;剔除文本信息不全或非典型政策形式,例如,标题中具有"征集""申报""推荐"字样的,以及内容为授奖、授予、通报、表彰等通知公告的。经过仔细筛选,最终获取 4441 篇科技政策文本,政策属性划分为强制型、鼓励型和引导型三类[34-35]。为了防止数据的标注出现错误,本研究采用多人混合识别方式,经过多人重复阅读政策文本,并按照以上的划分标准将所有文本标注为三个类别中的某一个,当所得分类结果均一致即标注为该类,若不一致则重新审核,通过内部投票和咨询相关专家等方式进行再次标识确认。经过多轮标识处理之后,此次实验数据包括强制型政策文本 1540 篇,鼓励型文本 753 篇,引导型文本 2148 篇。当然,人工判别也可能存在一定主观性,而基于深度学习的科技政策属性识别实验则可以通过对比人工判读与机器识别之间的差异实现某种意义的双向校验。这里采集的中国科技政策文本,其文本长度呈现出较典型偏态分布,最短的政策文本只有 600 多字,而最长的文本则超过 72,000 字,具体的文本长度分布如图 2 所示。

注:① https://www.pkulaw.com/

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

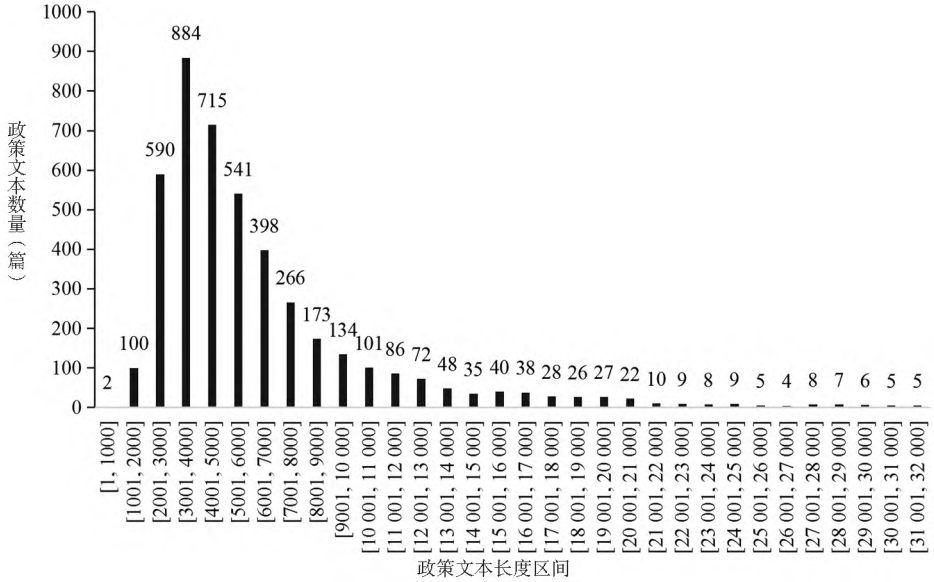

图 2　中国地方政府科技政策文本的长度分布

Figure 2　Text – length distribution of S&T policies of local governments in China

图 2 只列出了从 1 到 32 000 字之间的科技政策文本长度分布，从 32 000 到 73 000 字还有 39 篇文本，但分布区间较广，而区间［72 000，73 000］则只有 1 篇文本。每篇超过 2 万字的政策文本，笔者都进行了较为仔细地阅读，主要是检查是否有额外的附加字符，例如: 人员和机构名单，统计或年鉴数据、额外填充字符等。可以进一步计算图 2 的偏态系数，如式(9) 所示。

$$g_1 = \frac{K_3}{K_2\sqrt{K_2}} \tag{9}$$

其中，

$$K_2 = \frac{\sum (X-\bar{X})^2}{(n-1)} - \frac{1}{12};\quad K_3 = \frac{n\sum (X-\bar{X})^3}{(n-1)(n-2)} \tag{10}$$

根据式(9) 和(10) 可得到图 2 的偏态分布系数为 4. 034，本文选用 Matlab 中 Gauss3 函数进行拟合，Gauss3 函数解析式为式(11) 所示。

$$f(x) = a_1 e^{-\left(\frac{x-b_1}{c_1}\right)^2} + a_2 e^{-\left(\frac{x-b_2}{c_2}\right)^2} + a_3 e^{-\left(\frac{x-b_3}{c_3}\right)^2} \tag{11}$$

经过式(11) 的数值拟合可以得到参数值如表 1 所示。

表 1　图 1 偏态分布的高斯拟合结果

Table 1　Gaussian fitting results for skewed distributions in Figure 1

参数	取值	95% 置信区间
a_1	636. 3	(181. 8，1091)
b_1	3261	(3097，3424)
c_1	1262	(911，1613)
a_2	457. 2	(198. 1，716. 2)
b_2	5226	(3844，6607)
c_2	2251	(879. 1，3624)
a_3	108. 3	(60. 65，155. 9)
b_3	9484	(5645，1. 332e + 04)
c_3	5417	(2641，8192)

其中，根据公式(11) 拟合后的 *R – square* 为 0. 9965，*Adjusted R – square* 为 0. 9954，拟合效果较好，拟合图像如图 3 所示。

当截取长度为 x^* 时，则整个样本空间中所有样本总文本数据信息量函数即为每个区间段文本个数在文本信息量上的加权积分，也就可以表示为式(12) 。

$$W = \frac{1}{1000}\left(\int_0^{x^*} ((1+\eta)x - \eta x^*) f(x)dx + \int_{x^*}^{32000} x^* f(x)dx\right) \tag{12}$$

式(12) 中 $f(x) = a_1 e^{-\left(\frac{x-b_1}{c_1}\right)^2} + a_2 e^{-\left(\frac{x-b_2}{c_2}\right)^2} + a_3 e^{-\left(\frac{x-b_3}{c_3}\right)^2}$，且参数如表 1 所示。因此求出总文本数据信息量的最大值，可以转化为解决如下优化问题如式(13) :

$$\max_{0\leqslant x^*\leqslant 32000} W = \frac{1}{1000}\left(\int_0^{x^*} ((1+\eta)x - \eta x^*) f(x)dx + \int_{x^*}^{32000} x^* f(x)dx\right) \tag{13}$$

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

这里取白噪声系数为 $\eta = 1$，经过 Matlab 优化求解函数 fminbnd 求解可以得到 $x^* \approx 4722$，考虑到中文分词中，首先需要剔除停用词，标点符号，大约剔除整篇文章的 1/9 长度左右。由于大多数词语是由 2 个字组成的，所以在分词之后所需截取长度大概为剩余长度的一半左右。中文词语平均长度可能要略微长于 2 个字，因此，实际取词长度在 2000 基本可以达到理论信息量，同时又可保障一定的文本处理效率。

2.2 深度学习算法应用及对比

本文实验部分采用的软硬件设备参数为：(1) CPU 为 AMD Ryzen 5 2600X Six - Core Processor，3.60GHz，32G 内存，使用 6 个 GPU 加速，均为 NVIDIA GeForce RTX3070，8G 显存；(2) 操作系统为 64 位的 Windows 10；(3) 编程语言为 Python，使用 Pytorch 深度学习框架，而深度学习模型超参数如表 2 所示。

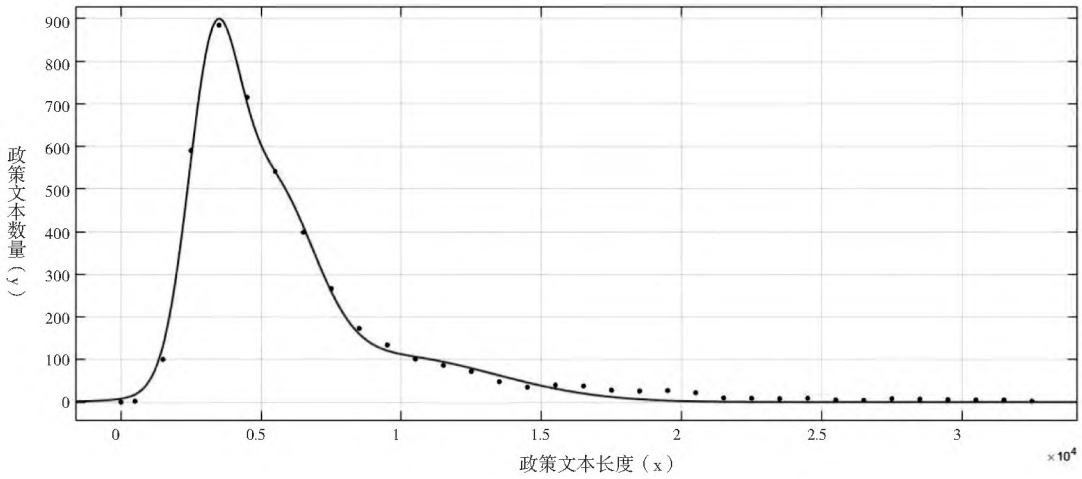

图 3 我国科技政策文本数据偏态分布的拟合效果

Figure 3 Fitting results of the skewed distributions of text - length of China´s S&T policies

表 2 深度学习模型的超参数设置

Table 2 Configuration of hyper - parameters for deep learning models

参数	含义	值	参数	含义	值
p_sr	文本增强同义词替换概率	0.25	p_ri	文本增强随机插入概率	0.25
p_rs	文本增强随机交换概率	0.25	p_rd	文本增强随机删除概率	0.25
batch_size	单次样本数量	256	learning rate	学习速率	0.001
num_workers	使用的线程数	4	weight_decay	损失函数正则化	0.0001
embed_size	词嵌入维度	300	max_epoch	所有样本训练次数	40
drop_prop	丢弃率	0.5	max_len	序列最大长度	500/750/1000
recurrent_hidden_size	循环层单元数	128	num_layers	循环层层数	2

考虑到此次所采集的中文科技政策文本的文本长度的中位数为：4883 字（含标点符号、空格和段落回车符）。此外，考虑到深度学习模型的计算耗时较长，实验分别取词 500，750，1000，2000，模型训练次数为 40 次，具体的实验结果如表 3 和表 4 所示。

表 3 在文献[44]的研究基础上做了进一步扩展，将取词长度增加到 2000 词。此外，这里还整合了基于注意力机制的深度学习模型，可以更全面探讨不同取词长度下，科技政策文本的识别效果。与之前的研究相比，本文探讨了不同深度学习策略在处理复杂文本时的效率和效果，为科技政策文本分析提供了更为丰富的研究的视角。从表 3 可以看出，针对中文科技政策属性的自动识别实验中，如果以 TextCNN 模型为基线，只有 FastText 模型和当前在自然语言理解领域较为主流的 Bi - LSTM + Attention 模型效果更好，尤其是 Bi - LSTM + Attention 模型的 F_1 值比 TextCNN 模型高出近 10%。同时，为了进一步考察 EDA 的文本增强对于科技政策属性识别的影响，相关的实验结果表 4 所示。

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

表 3　常见深度学习模型的科技政策属性识别效果对比（F_1 值）（单位：%）

Table 3　Comparison of identification results of Chinese S&T policy properties of traditional deep learning models (F_1 value) (unit: %)

模型	取词长度				均值
	500 词	750 词	1000 词	2000 词	
TextCNN	72.90	73.50	74.81	74.53	73.94
RCNN	71.90	72.90	77.15	77.56	74.88
CapsNet	68.03	68.65	69.25	69.14	68.77
FastText	75.50	78.05	79.03	83.10	78.92
Bi－LSTM	63.20	65.10	60.30	49.07	59.42
Bi－LSTM＋Attention	79.55	78.09	81.30	84.85	80.95
均值	71.85	72.72	73.64	73.04	

表 4　EDA 对于中文科技政策属性识别的影响（F_1 值）（单位：%）

Table 4　Impact of EDA on China´s S&T policy property identification (F_1 value) (unit: %)

模型	取词长度				均值
	500 词	750 词	1000 词	2000 词	
TextCNN	83.50	84.10	85.03	86.35	84.75
RCNN	80.78	83.09	84.69	84.56	83.28
CapsNet	77.86	78.50	79.40	80.09	78.96
FastText	85.30	86.50	86.45	88.42	86.67
Bi－LSTM	73.30	75.50	75.34	77.59	75.43
Bi－LSTM＋Attention	87.53	87.09	88.31	88.66	87.90
均值	81.38	82.46	83.20	84.28	

表 4 的实验结果可以反映出 EDA 算法所提到的文本增强操作显著提升了中文科技政策文本属性的识别效果。为了进一步验证 EDA 的效果不是因为简单样本数量扩充造成，本文也尝试通过简单文本复制方式扩充训练样本数量，实验显示这种方式扩大样本数量对于分类效果没有任何实质性影响，这也从一个侧面验证了 EDA 文本增强方法不仅适用于英文语料分析，也同样适用于中文长文本的文本挖掘。表 3 和表 4 的实验结果也显示在针对我国科技政策属性的自动识别实验中，中文取词长度从 500 词增加 2000 词的 F_1 值提升不显著，其中在中文科技政策文本进行分词之后，500 词的顺序取词长度大概包含 1000－1500 字（含标点符号），2000 词的顺序取词长度则为 4000－5000 字（含标点符号）。这个结论与公式（1）－（6）的文本信息量测算结果基本吻合。此外，考虑到近年自然语言处理领域较为热门的 BERT 模型可以直接进行文本分类，但 BERT 目前单个文本输入长度有 512 个 Token 的参数限制[45]，所以基于 BERT 模型的中文科技政策属性识别实验只比较 500 词的文本截取长度，其结果如表 5 所示。

从表 5 可以看出，最近较为热点的 BERT 模型在中文政策文本属性识别领域也具有较好的效果，其识别效果与 RCNN 和 TextCNN 模型接近，但由于 BERT 是多层 Transformer 模型和海量超参数的复杂叠加，其运行效率显著低于 TextCNN 和 RCNN，并且 BERT 的原始训练语料库（谷歌 AI 版本）来自英文维基百科和 BooksCorpus，其在英语自然语言理解数据集的表现更为优异[45]。

表 5　BERT 模型对于中文科技政策属性识别的效果（F_1 值）①（单位：%）

Table 5　Impact of BERT model on China´s S&T policy property identification (F_1 value) (unit: %)

模型	取词长度
	500 词
BERT	71.96
EDA＋BERT	82.89
均值	77.43

3　主要研究结论与启示

3.1　研究结论

鉴于深度学习相关模型在文本处理领域的显著优势，针对中文科技政策属性识别和文本分析相关科学问题，本文通过集成中文语料库、数据增强和经典的深度学习模型，构建了一个较为新颖的中文科技政策属性识别框架，从而进一步丰富和完善了科技政策文本分析的方法体系，

注：① BERT 模型的语言嵌入部分设定为 512 个 Token，真正嵌入的单词数量其实略少于 500 个单词。

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

主要结论如下。

(1) 综合对比近年主要的相关研究文献,若干经典深度学习模型在以短文本(例如:在线评论、微博和新闻头条等)分类和情感分析中,取得了较好效果,例如:Bi - LSTM[12] 和 CapsNet[16] 等,但在本文的中文科技政策属性自动识别中,Bi - LSTM 和 CapsNet 比 CNN、RCNN、FastText 和 BERT 等模型的效果略差,其中 F1 值最高的是 Bi - LSTM + Attention,但该算法耗时较长,计算效率相对偏低。

(2) 本文集成的数据增强算法(EDA)对于提升中文科技政策属性识别准确率和召回率均具有显著正向影响,而这种正向效应不是简单复制样本数量可以替代的,即 EDA 算法针对英语的四类操作算子在中文文本处理中依然具有显著效果。经过数据增强之后,基于深度学习模型的中文科技政策属性识别最高准确率超过了 88%,即:与人工阅读判别的差异不到 12%,这也部分反映出深度学习在自然语言理解、抽象学习和中文长文本挖掘领域的优势。

(3) 本文对中文政策文本取词长短的信息量估算进行了探讨,填补了相关研究盲点。从具体实验结果看,取词长度从 500 词增加 2000 词对于中文科技政策属性识别的效果提升不显著。该结论对于处理类似的政策文本属性识别问题也具有一定参考价值,但还需要在其他类似的中文政策文本中进一步验证。

3.2 研究启示

在人工智能技术快速发展的数字化时代,科技政策文本量化计算的重要性日益凸显。本文的研究成果为科技政策与科技管理领域提供了新的视角和工具,主要启示如下。

(1) 随着文本挖掘、机器学习和深度学习模型的进步,全文本分析和科技政策属性的自动识别已成为科技政策学和科技管理领域的前沿课题。这反映出从传统的依赖人工标签和判别的方法转向利用先进技术进行自动化处理的趋势。

(2) 基于深度学习的自然语言处理模型为长文本信息处理提供了强大的工具。本文的研究表明,这些模型在理解、抽象学习和中文长文本挖掘等方面表现出色,为政策文本分析带来新的可能性。

(3) 当前较为主流的 ChatGPT 作为 OpenAI 研发的人工智能聊天机器人在自然语言处理领域表现出了显著的优势,未来研究可以考虑融合这种先进模型,以进一步提升科技政策属性识别的准确性和效率。

3.3 研究不足与展望

当然,本文研究也存在一些局限性:一是考虑到当前已有大量文献比较了深度学习模型与传统机器学习模型在文本分类中的应用效果差异[12,18],本文就没有再和支撑向量机、朴素贝叶斯和逻辑回归等模型比较,可能会有一定争议;二是当前各类深度学习模型及其变种较多,本文的实验部分也只是选取了目前具有代表性的模型;三是本文实验部分只是选择了北大法宝网所存储的我国地方政府科技政策文本,相关结论在更为宽泛的政策文本环境是否也适用,还需在后续研究中进一步检验;四是在深度学习模型本身的可解释性问题依然存在一定挑战,需要在后续研究中进一步探讨。

参考文献:

[1] SILVER D, HUANG A, MADDISON C J, et al. Mastering the game of Go with deep neural networks and tree search [J]. Nature, 2016, 529(7587): 484 - 489.

[2] SILVER D, SCHRITTWIESER J, SIMONYAN K, et al. Mastering the game of Go without human knowledge [J]. Nature, 2017, 550(7676): 354 - 359.

[3] LITJENS G, KOOI T, BEJORDI B E, et al. A survey on deep learning in medical image analysis [J]. Medical Image Analysis, 2017, 42: 60 - 88.

[4] GU J X, WANG Z H, KUEN J, et al. Recent advances in convolutional neural networks [J]. Pattern Recognition, 2018, 77: 354 - 377.

[5] 王超. 深度学习在行业指数技术分析中的应用研究 [J]. 管理评论,2021,33(3):75 - 83.
WANG Chao. Study on applications of deep learning in technical analysis of sector indexes [J]. Management Review, 2021, 33(3):75 - 83.

[6] GUNNARSSON B R, BROUCKE S V, BAESENS B, et al. Deep learning for credit scoring: Do or don´t? [J]. European Journal of Operational Research, 2021, 295(1): 292 - 305.

[7] LEHRER S, XIE T, ZHANG X Y. Social media sentiment, model uncertainty, and volatility forecasting [J]. Economic Modeling, 2021, 102: 105556. DOI: 10.1016/j.econmod.2021.105556.

[8] 钟佳娃,刘巍,王思丽,等. 文本情感分析方法及应用综述 [J]. 数据分析与知识发现,2021,5(6):1 - 13.
ZHONG Jiawa, LIU Wei, WANG Sili, et al. Review of methods and applications of text sentiment analysis [J]. Data Analysis and Knowledge Discovery, 2021, 5(6): 1 - 13.

[9] WU H P, LIU Y L, WANG J W. Review of text classification methods on deep learning [J]. CMC - Computers Materials & Continua, 2020,63 (3): 1309 - 1321.

[10] 张海涛,王丹,徐海玲,等. 基于卷积神经网络的微博舆情情感分类研究 [J]. 情报学报,2018,37(7): 695 - 702.
ZHANG Haitao, WANG Dan, XU Hailing, et al. Sentiment classification of micro - blog public opinion based on convolution neural network [J]. Journal of the China Society for Scientific and Technical Information, 2018, 37(7): 695 - 702.

[11] GUO B, ZHANG C X, LIU J M, et al. Improving text classification with weighted word embeddings via a multi - channel TextCNN model [J]. Neurocomputing, 2019, 363: 366

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

－374.

[12] 吴鹏，应杨，沈思. 基于双向长短期记忆模型的网民负面情感分类研究 [J]. 情报学报，2018，37(8)：845－853.
WU Peng，YING Yang，SHEN Si. Negative emotions of online users´ analysis based on bidirectional long short－term memory [J]. Journal of the China Society for Scientific and Technical Information，2018，37(8)：845－853.

[13] 贺鸣，孙建军，成颖. 基于朴素贝叶斯的文本分类研究综述 [J]. 情报科学，2016，34(7)：147－154.
HE Ming，SUN Jianjun，CHENG Ying. Text classification based on naive Bayes：A review [J]. Information Science，2016，34(7)：147－154.

[14] SINOARA R A，CAMACHO－Collados J，ROSSI R G，et al. Knowledge－enhanced document embeddings for text classification [J]. Knowledge－based Systems，2019，163：955－971.

[15] LI Q，LI P F，MAO K Z，et al. Improving convolutional neural network for text classification by recursive data pruning [J]. Neurocomputing，2020，414：143－152.

[16] XIE J B，HOU Y J，WANG Y J，et al. Chinese text classification based on attention mechanism and feature－enhanced fusion neural network [J]. Computing，2020，102(3)：683－700.

[17] DENG J F，CHENG L L，WANG Z W. Attention－based BiLSTM fused CNN with gating mechanism model for Chinese long text classification [J]. Computer Speech And Language，2021，68：101182. DOI：10.1016/j.csl.2020.101182.

[18] 李娜，姜恩波，朱一真，等. 政策工具自动识别方法与实证研究 [J]. 图书情报工作，2021，65(7)：115－122.
LI Na，JIANG Enbo，ZHU Yizhen，et al. Policy tool identification method and empirical research based on deep learning [J]. Library and Information Service，2021，65(7)：115－122.

[19] 胡吉明，付文麟，钱玮，等. 融合主题模型和注意力机制的政策文本分类模型 [J]. 情报理论与实践，2021，44(7)：159－165.
HU Jiming，FU Wenlin，QIAN Wei，et al. Research on policy text classification model based on topic model and attention mechanism [J]. Information Studies：Theory & Application，2021，44(7)：159－165.

[20] ARRIETA A B，DIAZ－Rodriguez N，DEL Ser J，et al. Explainable Artificial Intelligence (XAI)：Concepts，taxonomies，opportunities and challenges toward responsible AI [J]. Information Fusion，2020，58：82－115.

[21] TSAI K C，WANG L，HAN Z. Caching for mobile social networks with deep learning：Twitter analysis for 2016 US election [J]. IEEE Transactions on Network Science and Engineering，2020，7(1)：193－203.

[22] SAHOO S R，GUPTA B B. Multiple features based approach for automatic fake news detection on social networks using deep learning [J]. Applied Soft Computing，2021，100：106983. DOI10.1016/j.asoc.2020.106983.

[23] LI S B，HU J，CUI Y X，et al. DeepPatent：Patent classification with convolutional neural networks and word embedding [J]. Scientometrics，2018，117(2)：721－744.

[24] YI X，WALIA E，BABYN P. Generative adversarial network in medical imaging：A review [J]. Medical Image Analysis，2019，58：101552. DOI：10.1016/j.media.2019.101552.

[25] WANG X，WANG K，LIAN S G. A survey on face data augmentation for the training of deep neural networks [J]. Neural Computing & Applications，2020，32(19)：15503－15531.

[26] 张一珂，张鹏远，颜永红. 基于对抗训练策略的语言模型数据增强技术 [J]. 自动化学报，2018，44(5)：891－900.
ZHANG Yike，ZHANG Pengyuan，YAN Yonghong. Data augmentation for language models via adversarial training [J]. Acta Automatica Sinica，44(5)：891－900.

[27] 李茜茜，沈晓燕，任福继，等. 面向数据增强的多种语音情感分类算法研究 [J]. 智能系统学报，2021，16(1)：170－177.
LI Qianqian，SHEN Xiaoyan，REN Fuji，et al. Investigation of multiple speech emotion classification algorithms based on data enhancement [J]. CAAI transactions on intelligent systems，2021，16(1)：170－177.

[28] 陆垚杰，林鸿宇，韩先培，等. 基于语言学扰动的事件检测数据增强方法 [J]. 中文信息学报，2019，33(7)：110－117.
LU Yaojie，LIN Hongyu，HAN Xianpei，et al. Linguistic perturbation based on data augmentation for event detection [J]. Journal of Chinese Information Processing，2019，33(7)：110－117.

[29] 刘彤，刘琛，倪维健. 多层次数据增强的半监督中文情感分析方法 [J]. 数据分析与知识发现，2021，5(5)：51－58.
LIU Tong，LIU Chen，NI Weijian. A semi－supervised sentiment analysis method for Chinese based on multi－level data augmentation [J]. Data Analysis and Knowledge Discovery，2021，5(5)：51－58.

[30] WEI J，ZOU K. EDA：Easy data augmentation techniques for boosting performance on text classification tasks [J/OL]. arxiv preprint arxiv：1901.11196，2019. https://arxiv.org/abs/1901.11196，2019.

[31] EKBOIR J M. Research and technology policies in innovation systems：Zero tillage in Brazil [J]. Research Policy，2003，32(4)：573－586.

[32] MOROSINI P. Industrial clusters，knowledge integration and performance [J]. World Development，2004，32(2)：305－326.

[33] ONISHI A. A new challenge to economic science：Global model simulation [J]. Journal of Policy Modeling，2010，32(1)：1－46.

[34] 张永安，耿喆，王燕妮. 区域科技创新政策分类与政策工

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

具挖掘: 基于中关村数据的研究 [J]. 科技进步与对策, 2015, 32(17): 116 – 22.
ZHANG Yongan, GENG Zhe, WANG Yanni. Regional science and technology innovation policy classification and policy tools mining based on Zhongguancun data [J]. Science & Technology Progress and Policy, 2015, 32(17): 116 – 122.

[35] 张宝建, 李鹏利, 陈劲, 等. 国家科技创新政策的主题分析与演化过程: 基于文本挖掘的视角 [J]. 科学学与科学技术管理, 2019, 40(11): 15 – 31.
ZHANG Baojian, LI Pengli, CHEN Jin, et al. Thematic analysis and evolution process of national science and technology innovation policy: Based on the perspective of text mining [J]. Science of Science and Management of S. & T., 2019, 40(11): 15 – 31.

[36] 陈玲, 段尧清. 我国政府开放数据政策的实施现状和特点研究: 基于政府公报文本的量化分析 [J]. 情报学报, 2020, 39(7): 698 – 709.
CHEN Ling, DUAN Yaoqing. Analyzing implementation of the Chinese government open data policy using government bulletin text as example [J]. Journal of the China Society for Scientific and Technical Information, 2020, 39(7): 698 – 709.

[37] 杨锐, 陈伟, 何涛, 等. 融合主题信息的卷积神经网络文本分类方法研究 [J]. 现代情报, 2020, 40(4): 42 – 49.
YANG Rui, CHEN Wei, HE Tao, et al. Text classification method based on convolutional neural network using topic information [J]. Journal of Modern Information, 2020, 40(4): 42 – 49.

[38] 黄水清, 王东波. 新时代人民日报分词语料库构建、性能及应用(二): 深度学习自动分词模型构建 [J]. 图书情报工作, 2019, 63(23): 5 – 12.
HUANG Shuiqing, WANG Dongbo. Construction, performance and application of new era People´s Daily segmented corpus (Ⅱ): Constructing automatic word segmentation model of deep learning [J]. Library and Information Service, 2019, 63(23): 5 – 12.

[39] 王昊, 邓三鸿, 苏新宁, 等. 基于深度学习的情报学理论及方法术语识别研究 [J]. 情报学报, 2020, 39(8): 817 – 828.
WANG Hao, DENG Sanhong, SU Xinning, et al. A study on Chinese terminology recognition of theory and method from information science: Based on deep learning [J]. Journal of the China Society for Scientific and Technical Information, 2020, 39(8): 817 – 828.

[40] HUANG Y, CHEN J, ZHENG S, et al. Hierarchical multi – attention networks for document classification [J]. International Journal of Machine Learning and Cybernetics, 2021, 12(6): 1639 – 1647.

[41] ZHENG X, CHEN W Z. An attention – based Bi – LSTM method for visual object classification via EEG [J]. Biomedical Signal Procesing and Control, 2021, 63: 102174. DOI10.1016/j.bspc.2020.102174.

[42] 施国良, 陈宇奇. 文本增强与预训练语言模型在网络问政留言分类中的集成对比研究 [J]. 图书情报工作, 2021, 65(13): 96 – 107.
SHI Guoliang, CHEN Yuqi. A comparative study on the integration of text enhanced and pre – trained language models in the classification of Internet political messages [J]. Library and Information Service, 2021, 65(13): 96 – 107.

[43] KIM S, PARK H, LEE J. Word2vec – based latent semantic analysis (W2V – LSA) for topic modeling: A study on blockchain technology trend analysis [J]. Expert Systems with Applications, 2020, 152: 113401. DOI10.1016/j.eswa.2020.113401.

[44] 李牧南, 王良, 赖华鹏. 中文科技政策文本分类: 增强的 TextCNN 视角 [J]. 科技管理研究, 2023, 43(2): 160 – 166.
LI Munan, WANG Liang, LAI Huapeng. Text classification of Chinese S&T policies: Enhanced TextCNN perspective [J]. Science and Technology Management Research, 2023, 43(2): 160 – 166.

[45] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre – training of deep bidirectional transformers for language understanding [J/OL]. rxiv preprint arxiv: 1810.04805, 2018. https://arxiv.org/pdf/1810.04805.pdf, 2019, 05.

[46] 冯国明, 张晓, 刘素辉. 基于 CapsNet 的中文文本分类研究 [J]. 数据分析与知识发现, 2018, 2(12): 68 – 76.
FENG Guoming, ZHANG Xiaodong, LIU Suhui. Classifying Chinese texts with CapsNet [J]. Data Analysis and Knowledge Discovery, 2018, 2(12): 68 – 76.

Identification of China´s S&T policy properties based on deep learning

Li Munan[1,2], Wang Liang[1], Lai Huapeng[1]

(1. School of Business Administration, South China University of Technology, Guangzhou 510641, Guangdong, China;
2. Guangdong Key Lab on Innovation Methods & Decision Management System, Guangzhou 510641, Guangdong, China)

Abstract: The current text analysis based on deep learning algorithm focuses more on short text information processing such as public opinion monitoring and sentiment analysis represented by microblog, online comments and news headlines and so on,

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

while there are few related research on property identification and long text classification of various policy texts, paper full – text and patent full – text, which has significant room for exploration and expansion. Compared with traditional machine learning models, the relevant models or algorithms on deep learning have significant advantages in NLP (natural language processing) and text feature extraction. Deep learning algorithms can reduce manual intervention in feature engineering through pre – training language models, and thus has a promising application prospect in such fields as policy attribute or property identification and policy – instrument recognition. This paper aims at the automatic identification of the properties of science and technology policies, and the properties of policy are divided into such types as guiding, compulsory and encouraging. The main approach is to import several popular models of deep learning for comparative analysis. At the same time, this paper also carried out theoretical analysis on related computing problems such as (1) the impact on property identification among the different text length of policies; (2) the impact of data augmentation of text data; (3) and facilitate the information estimation of policy texts. In order to further enrich the application of deep learning model in scientometrics and informetrics, especially in the field of text analysis on science and technology policies, the experiments on property identification of science and technology policies form China local governments were conducted based on those selected models of deep learning, which are very popular in the latest studies on text classification. The theoretical and empirical analysis showed that the current representative deep learning models have significantly enhanced their processing capacity for property identification of science and technology policy after manipulation of data augmentation based on the EDA (Easy Data Augmentation) method that just presents the excellent performance in the English text processing in the relevant studies. The identifying accuracy of EDA + bi – LSTM – Attention was more than 88%, and the average recognition accuracy of the other deep learning models (TextCNN, Bi – LSTM, RCNN, CapsNet and FastText, etc.) also can reach over 80% after text augmentation based on the EDA method. However, increasing the length of text interception from 500 words to 2000 words has no significant effect on the property – identification of Chinese science and technology policy, and these experimental results could also be useful for the following studies on policy – text analyses because it implied the full – text of policy could be unnecessary in the similar task of long – text processing. The research of this paper has certain significance of enlightenment and reference value for the quantitative analysis of science and technology management, such as automatic identification of science and technology policy attributes, classification of Chinese long text and identification of policy tools. Meanwhile, the output of this paper could be controversial for the limited policy – text, and in another data source of policy – text, e. g. energy policies, environment policies and financial policies and so on, whether those mentioned models of deep learning in this paper are still effective, should be further explored and discussed the future work.

Keywords: deep learning; science and technology policy; property identification; data augmentation; text classification

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net