机器学习与会计舞弊治理：基于非遴选因子的预测视角

周　玮　王　松　徐玉德　申　峰*

内容提要　本文研究将机器学习引入资本市场监管，优化会计舞弊治理的理论和现实问题。使用1998-2021年会计舞弊数据，采用8种主流机器学习模型，从非遴选因子视角评估机器学习遏制会计舞弊的优势和潜力。研究发现，使用机器学习预测会计舞弊，并不依赖事前因子遴选，预测效果超过了事前遴选会计指标的各种组合，预测指标AUC平均提升12.22%。分析表明这与事前遴选指标更容易受到市场针对性的规避行为有关。在此基础上，本文进一步讨论了机器学习优化中国资本市场"双随机、一公开"抽检政策的潜力，认为引入机器学习能够大幅提高会计舞弊检出数量，降低重大舞弊案例的发现阈值，缩短会计舞弊的处罚时滞，从而遏制会计舞弊的扩张。

关键词　会计舞弊　机器学习　非遴选因子　会计比率

DOI:10.19985/j.cnki.cassjwe.2024.11.006

一　引言

上市公司会计舞弊治理是投资者保护的焦点和资本市场健康发展的保障(Shleifer and Wolfenzon，2002；La Porta *et al.*，2000，2006)。在中国资本市场中，证券监督管理委员会(以下简称证监会)及其派出机构实施的主动执法对会计舞弊治理发挥了决定性

*　周玮、王松：西南财经大学金融学院；徐玉德：中国财政科学研究院；申峰(通讯作者)：西南财经大学金融学院　西南财经大学智能金融教育部工程研究中心　电子信箱：zhouwei@swufe.edu.cn(周玮)，wangsongup@163.com(王松)，xuyude352@sina.cn(徐玉德)，shenfeng@swufe.edu.cn(申峰)。

本研究得到教育部人文社科规划项目(23YJA790109，22JJD790067)、国家自然科学基金(72001178)以及西南财经大学中央高校项目(JBK2406005)的资助，作者感谢匿名审稿专家的宝贵意见，当然，文责自负。

中国知网　https://www.cnki.net

作用(辛宇等,2020;Ke and Zhang,2021;陈运森等,2021)。2014年以来,证监会陆续建立和完善了中小投资者服务中心、集体诉讼、强制退市等一系列基础设施制度,对会计舞弊处以天价处罚,诉诸严厉的刑事责任追溯,增强信息披露的事中和事后监督。然而,市场监管的强化和执法改革的深入,并没有彻底遏制会计舞弊行为的扩张,甚至出现如康美药业这种舞弊金额动辄数百亿的行业龙头和明星公司,形成公众对于会计舞弊治理的信任舆情。近年来,会计舞弊呈现数量快速增加、经济后果日趋严重的特征(见图1),引发对于证券监管公共执行机制的效率和效力的思考:在公共资源有限和信息不对称的现实约束下,如何进一步提高监管执法的效率,遏制会计舞弊?

Posner(1973)认为,加大执法力度,提高对会计舞弊行为处罚的确定性和严厉性能够遏制市场违规行为。然而,执法机构面临着巨大的挑战,难以对所有潜在的违法行为进行全面监管。首先,由于执法资源有限,执法机构无法覆盖所有的潜在违法行为,导致一些违法行为未被有效监管;其次,由于信息不对称,一些公司通过隐瞒或掩盖真实情况来规避执法机构的监管,从而降低了被发现的风险。当执法效率较低时,公司可能会认为自己的舞弊行为不太可能被发现,从而使得舞弊行为的预期成本降低。这将导致会计舞弊行为的预期净收益增加,从而增强公司从事此类活动的动机。

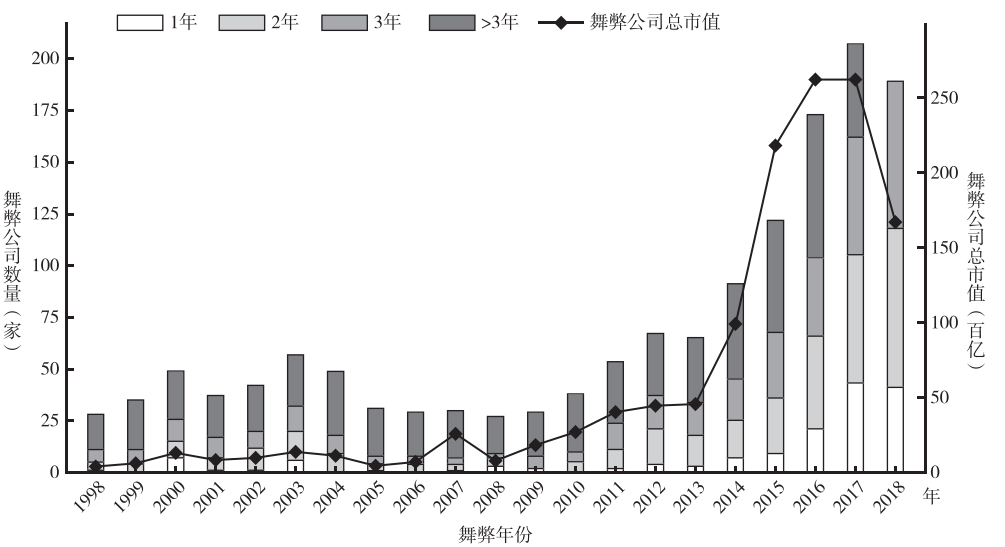

图1 中国上市公司会计舞弊行为的年度分布情况

说明:本图报告了不同会计年度发生会计舞弊的公司数量。由于查出会计舞弊存在时滞,图中同时标识了会计报告披露当年被查出舞弊(1年)、会计报告披露下一年被查出舞弊(2年)、会计报告披露后的第3年被查出舞弊(3年)以及会计报告披露后3年以上被查出舞弊(>3年)的公司数量。

中国知网 https://www.cnki.net

提高会计舞弊预测的准确性和及时性,是改善执法效率、降低经理人逆向选择的重要路径(Chen *et al.*,2011)。监管机构、学术研究者和业界实践人员从舞弊案例、博弈模型以及经验研究出发对会计舞弊行为进行了大量的分析和总结(吴联生和王亚平,2003;杨柏,2005;张新民和陈德球,2020)。当发现特定会计科目被用于会计舞弊后,监管机构会针对此类科目变化异常或者关联科目会计比率异常的公司展开调查。在中国,证券监管机构选择问询、约谈、调取中介机构底稿、现场检查等综合调查手段,核查高风险公司(吕成龙,2018)。上市公司识别监管逻辑后,采用分散会计科目记录、管理关键会计比率等方式规避监管"视线",进而操纵会计报告实现特定会计目标。双方"猫捉老鼠"的躲闪不断提高会计舞弊被发现的难度和市场调查所需资源。总体上,会计舞弊行为的隐蔽性增加与执法资源扩张的现实约束,抑制了会计舞弊治理效率的提升。

机器学习的发展为提高会计舞弊治理效率提供了新思路。将机器学习应用于会计舞弊预测的优势在于:第一,机器学习迭代升级快,适应市场规则变化能力强,有利于抑制针对性的会计粉饰行动;第二,机器学习善于处理高维数据集合,模型的泛化能力高,适合通过扩张信息集来提升预测准确性,降低因子遗漏对预测效果的影响;第三,机器学习典型的"学习-训练-预测"模式,有助于降低会计舞弊判断的主观性偏误,克服选择性执法对公共执行效率的影响。本文研究了主流机器学习模型对会计舞弊的预测表现,证实了机器学习不依赖预先因子遴选就能获得更高的预测优势,讨论了机器学习在中国资本市场监管实践中,对于提高当前"双随机、一公开"抽检策略的潜力和缩短会计舞弊暴露时滞的优势,从而展示出应用机器学习提升监管执法效率,优化会计舞弊治理的现实意义和积极作用。

Cecchini *et al.*(2010)最早尝试开发专用的机器学习模型用于会计舞弊预测,该研究用机器学习替代经典二分模型(Logit回归),使用由原始会计科目生成的会计比率集合预测会计舞弊,结果发现预测准确性显著提高。Bao *et al.*(2020)认为机器学习使用原始会计科目而非会计比率能够获得更多预测信息,该研究将特定的会计比率分拆成会计科目后进行会计舞弊预测,进一步提升预测准确性。上述研究开启了机器学习用于会计舞弊治理的广泛讨论。然而,一些重要问题还需要进一步阐明:(1)现有机器学习的文献,目的在于证实机器学习取代Logit回归等经典二分模型解决预测问题的优势,出于比较的需要,预测因子都是遴选自特定的会计比率或是会计科目集合,这些会计比率和科目来自先前经验研究的积累和逻辑推断。然而,预先遴选因子并不利于发挥机器学习的优势,遴选必然存在一定程度的因子遗漏,研究人员的认知滞后也可能造成遴选"脱靶",这些都会影响会计舞弊的预测效果;(2)目前的研究重在讨论应用

中国知网 https://www.cnki.net

机器学习改善会计舞弊治理的理论优势,但缺乏对机器学习应用的局限分析和现实约束的考虑,不利于充分了解机器学习应用的实践效果。机器学习的理论优势与抽检阈值设定相关,变更抽检阈值严重受到公共资源供给的限制,大规模推动机器学习应用也将改变目前公共监管资源的分配结构,所以,从市场实践出发,分析机器学习预测优势的现实取舍,对于改善会计舞弊治理更具有现实意义;(3)将机器学习用于改善会计舞弊治理在不同制度背景下的市场存在差异,需要增加对机器学习在中国资本市场会计舞弊治理中理论价值和现实意义的了解。与美国资本市场会计舞弊发生率不到1%相比(Bao *et al.*,2020),中国最近20年的会计舞弊平均水平约为3.57%(见表1),并且持续上升,遏制会计舞弊的需求迫切,改善空间更大,尤其是诉讼机制及其配套制度建设在中国并未发展成熟,治理会计舞弊十分依赖监管实施的主动监督行为,机器学习对于改善中国资本市场会计舞弊治理水平具有更强的边际效力。

本文从非遴选预测因子的视角,研究了机器学习对于发现年度会计报表舞弊的优势。年度会计报表是以簿记方式记录企业经营行为的标准化报告,包括资产负债表、利润表和现金流量表,中国年度会计报表共包括331个会计科目,这些会计科目及其组合的比率揭示了企业经营目标的实现和价值增长的现状。为了验证机器学习可以不依赖遴选因子就能获得更高的预测效果,本文将会计报表全部331个会计科目直接作为因子引入了预测模型。同时,为了与预先遴选进行比较,本文按照Bao *et al.*(2020)的做法,以Cecchini *et al.*(2010)、Dechow *et al.*(2011)归纳的14个会计比率为遴选因子引入对照模型。本文共选择了8种主流机器学习模型,包括套索逻辑回归(LASSO-Logit)、支持向量机(SVM)、随机欠采样提升算法(RUSBoost)、极端梯度提升算法(XGBoost)、随机森林(Random Forest)、轻量梯度提升机(LightGBM)、注意力解释性表格学习(TabNet)和神经无记忆决策集成算法(NODE),预测效果使用受试者工作AUC(Area Under Curve,受试者工作特征曲线以下的面积)评价,该指标取值在0到1之间,0.5代表预测相当于随机猜测,AUC越大预测效果越好。

本文使用1998-2021年上市公司年度财务报表和会计舞弊的数据,研究发现:机器学习预测会计舞弊,并不依赖事前因子遴选,8种主流机器学习模型的预测效果都超过了事前遴选会计指标的各种组合,预测指标AUC平均提升12.22%。分析表明这与事前遴选的会计指标受到资本市场针对性的规避有关。进一步的研究验证了非遴选因子模式下机器学习对于优化中国资本市场“双随机、一公开”抽检制度的潜力。引入机器学习能够大幅提高会计舞弊检出数量,最高超出217.5%。对于测试期间处罚金额最大的10起会计舞弊案例,机器学习将抽检阈值缩小58.89%。在会计舞弊发

中国知网 https://www.cnki.net

生当年,机器学习能够将检出数量提升58.33%,缩短会计舞弊的处罚时滞。

本文贡献在于:第一,首次从非遴选因子视角,分析了机器学习预测用于改善会计舞弊治理的理论优势和现实意义。目前对会计舞弊预测的研究主要围绕解释力强的因子展开,或是以重要特征因子为抓手进行调查,或是通过扩张因子数量提高模型拟合度,少量文献讨论机器学习对舞弊预测的应用,也是以因子遴选为基础强调机器学习替代经典二分模型(Logit回归)的可行性。然而,现有的研究都没有回答一个重要的问题——预测会计舞弊,机器学习究竟需不需要预先因子遴选?理论上,如果机器学习预测会计舞弊不依赖研究人员预先遴选因子,那么,模型和算法的优化、创新将是未来解决会计舞弊问题的重要路径。本文研究发现,遴选的会计比率逐渐变得相对"普通",会计科目对于识别会计舞弊的重要性经常发生此消彼长的变化,表明市场存在针对特定会计比率或会计科目的规避行为。使用非遴选因子进行预测,意味着市场上针对性的会计粉饰行动失去目标,更高的预测准确性有助于改善执法资源使用效率,遏制会计舞弊行为的扩张。

第二,本文从提高随机抽检发现概率出发,揭示了非遴选因子条件下,机器学习对于改善"双随机、一公开"监管制度的实践价值。监管部门推动随机抽检的目的在于防范监管活动对市场过度干预,增强市场主体守法的自觉性。在保持抽检比例不变的情况下,机器学习可以将随机抽检发现的会计舞弊数量扩张三倍以上,非遴选方式也有利于发挥随机抽检的治理效用,缓解"监管不公、检查任性、执法不力"的选择性执法问题。本文的研究表明,在非遴选因子的基础上,将机器学习引入随机抽检实践,能够大大提升证券监管执法的威慑力。

第三,本文为中国资本市场推动金融监管创新,提供了提升监管效率和效力的研究依据和完善方向。监管科技化以及由此形成的科技驱动性监管是监管模式和理论的突破性重构,证券监管创新日益成为实践和研究的焦点。现有文献对于机器学习改善中国资本市场会计舞弊的研究还存在不足,多数文献以美国资本市场为研究对象,美国资本市场的私人执行机制较为完善、公共执行机制有效性较低(La Porta *et al.*, 2006;Christensen *et al.*,2020),制度背景与中国显著不同,来自本土资本市场的研究证据对于推动中国金融监管创新至关重要。本文从机器学习改善中国资本市场会计舞弊治理出发,基于调整公共执法资源分配和缩短会计处罚时滞的视角,分析机器学习对于提升市场监管效力的帕累托改进效果,为金融科技助力市场监管创新提供了中国新兴资本市场的经验证据。

本文的其余部分结构安排如下:第二部分是会计舞弊预测与机器学习相关的理

中国知网 https://www.cnki.net

论和实践发展;第三部分是机器学习用于预测会计舞弊的经验研究设计;第四部分是研究结果;第五部分讨论机器学习在现实抽检策略下的检出优势;第六部分是结论和政策启示。

二 会计舞弊预测与机器学习

(一)监管效率与会计舞弊治理

根据规定,上市公司需要定期披露报告,其中尤以年度会计报告最为重要,它是市场监督其会计舞弊的重点。中国证券市场会计舞弊治理主要由监管机构实施的主动监督行为推动,根据证监会2015年上半年稽查执法统计,沪深交易所上报和证监会日常监管所提供的稽查执法线索占比达83%(中国证监会,2015),监管遵循各国普遍接受的"依职权调查原则"①,由证监会或其指定代理人负责日常监督,拥有调查、取证、查审、处罚的执法权限(中国证监会,2021),收集来自公众举报、媒体报道、其他政府部门移交、证监会派出机构日常监管以及证券交易所报告的线索。证监会设立调查部门对线索进行初期审查,提出立案建议,报负责人批准并实施进一步取证核查工作,通常监管部门会根据线索预判高风险群体,确定调查方向。

会计舞弊治理对证券监管有较高的专业性要求,会计年报需要证券监管人员具备财务、法律等专业教育背景,拥有和积累较强的财务信息解读能力和行业经验,才能对其合理性做出准确判断。面对会计舞弊创新,证监会有时还会从行业一线聘请专家,提高会计舞弊的鉴别能力(Chen *et al.*,2005)。在内控制度上,为了预防合谋风险,证券交易所强制要求任职七年及以上的关键敏感岗位人员应竞聘其他部门进行轮岗。

由此可见,会计舞弊的调查和取证需要付出高昂的时间和执法成本,受人员编制、专业水平、预算控制和执法程序的约束,证券监管部门无法对全部公司的舞弊风险实施充分的取证核查,只能以一定概率随机执行(钱爱民和朱大鹏,2020)。在确认调查指向后,监管机构为提高稽查准确性,需要增加取证、核查的范围,这会导致会计舞弊处罚迟缓冗长,因此,扩大调查范围面临着人力、物力和方法等现实条件的约束,往往滞后于会计舞弊事件的增长。

① 提交立案前,监督管理部门初步调查的内部机构不仅包括稽核部门,也包括获得线索的其他有关职能部门,这与成熟市场的国家和地区略有差异。美国证券交易委员会明确非正式调查只能由执行部统一进行,香港证券及期货事务监察委员会的非正式调查为法规执行部进行,主要是避免调查对象被侵扰或是引起调查对象察觉,给后续调查带来干扰。

中国知网 https://www.cnki.net

执法效率低下会削弱证券监管的威慑力。有效的会计监督和严格的执法机制是维护市场秩序的重要制度安排,如果这种制度安排因为执法效率低下而失效,会计舞弊者会认为他们可以规避法律制裁,进而助长违法行为的蔓延。在这种情况下,制度本身的威慑作用被削弱,导致更多的市场参与者选择铤而走险。

(二)会计舞弊识别与特征指标

是否存在会计舞弊依赖具有丰富经验的一线监管人员判断,学术研究也为会计舞弊提供指针性识别工具,帮助监管机构对舞弊行为做出初步判断。2013年,美国证监会针对会计舞弊成立了财务报告和审计工作组,公开声明其广泛利用研究会计舞弊的学术工作成果来发现会计舞弊行为(Securities and Exchange Commission (SEC),2020)。

大量学术研究分析和讨论了会计舞弊的特征指标,大致围绕两个方向。一是观察舞弊公司的会计特征,寻找识别会计舞弊的"红旗"指标(Albrecht *et al.*,1986)。例如Persons(1995)提出舞弊公司财务杠杆更高,资本周转率更低,流动资产比率更高,大部分涉及存货和应收账款。会计应计和现金流(Jones,1991;Dechow *et al.*,1995;Kothari *et al.*,2005)、收益年度变化(Graham *et al.*,2005)、应税科目(Phillips *et al.*,2003)也被发现与操纵盈余的舞弊相关。Cecchini *et al.*(2010)、Dechow *et al.*(2011)和Perols(2011)统计了先前研究,提出要从应计项目、财务业绩、非财务指标、表外业务和市场指标五个方面综合识别会计舞弊,构建预测会计舞弊的会计比率组合;Perols *et al.*(2017)在该组合基础上加入更多会计比率,结果发现模型对会计舞弊的预测能力还会进一步提高。事实上,监管双方存在针对会计舞弊识别的对抗性博弈(Beasley *et al.*,1999、2010),研究中发现新的强解释力的会计比率很可能意味着先前的会计比率已经失去识别效力,需要持续跟踪和扩张会计舞弊识别的会计比率组合。

二是从舞弊动机判断舞弊风险。整体上,市值管理、薪酬目标、业绩目标、融资支持、规避违约和政府干预都得到较多的研究证据支持。由于舞弊通过会计手段实现,舞弊动机往往与会计指标相关联。如DeFond and Jiambalvo(1994)发现债务融资约束越大,会计应计水平越高,公司越可能通过应计项目管理盈余目标,获得更多的融资支持。同时,舞弊动机不依赖于特定会计比率实现,舞弊路径呈现时段性、多样化的特点(张蕊,2010)。中国学者从20世纪90年代开始对会计舞弊问题展开研究,研究主要聚焦于对盈余管理行为的发现和测度(吴东辉,1999;陆建桥,1999;耿建新和肖泽忠,2002;白云霞等,2005)。中国独特的制度背景带来很多具有中国特色的舞弊动机的讨论,如国有股权的掏空(王化成等,2015;刘少波和马超,2016)、政府补贴获取

中国知网 https://www.cnki.net

(王红建等,2014;赵璨等,2015)、股东减持(蔡海静等,2017)等。舞弊动机包含了隐蔽性较高的会计特征,能缓解会计舞弊预测模型的因子遗漏问题。钱苹和罗玫(2015)使用会计指标和舞弊动机共同对会计舞弊进行了预测,发现预测能力高于单纯会计比率模型。

(三)机器学习与会计舞弊预测

机器学习模型相较于传统计量模型具有多方面的优势:更擅长处理高维度数据;更容易拟合非线性关系;更擅长处理高相关性变量之间的冗余变化;预测函数的形式更加灵活多变;突破以往有关先验分布假设的约束(Geng *et al.*,2015;Gu *et al.*,2020;陈云松等,2020)。以Logit回归为代表的广义线性模型在因果推断的解释性与模型结果的稳定性方面存在优势,但其对特征变量的约束较多,难以拟合非线性的复杂问题,样本外预测能力较弱。

随着大数据和人工智能的发展,机器学习在会计舞弊预测中的跨领域应用逐渐受到关注。Cecchini *et al.*(2010)首次开发了针对会计舞弊的SVM模型,其内核可以将输入的原始会计科目映射为更广泛的会计比率特征;Liu *et al.*(2015)首次应用Random Forest模型提升中国会计舞弊的预测效果;Bao *et al.*(2020)使用结合欠采样和集成学习的RUSBoost模型,输入原始会计科目而非会计比率,相较于输入相同特征的Cecchini *et al.*(2010)SVM模型,预测效果提高了15.81%;Bertomeu *et al.*(2021)将梯度提升回归树模型引入会计舞弊预测领域;刘云菁等(2022)开发了基于LightGBM的会计舞弊预测模型;周卫华等(2022)提出了基于XGBoost的Xscore会计舞弊预测模型。

现有研究的会计舞弊预测因子大多是基于特定会计比率或会计科目,分析中使用到的预测因子通过经验研究的积累和逻辑推断、遴选得到,这样做的后果是可能造成预测因子遗漏,影响会计舞弊识别效果。对于事先遴选会计舞弊预测因子是否局限机器学习的预测效果,缺乏了解和研究。更为重要的是,现有研究侧重讨论不同机器学习模型在会计舞弊预测效果上的理论差异,缺乏关于机器学习在会计舞弊监管业务场景中改善资源约束和提升执法效率的深入分析。

三 经验研究设计

(一)样本数据

本研究中,会计舞弊的样本来源于万得(Wind)中国上市公司违规行为数据库。该数据库收集了1998-2021年证监会、地方证监局、证券交易所和财政部对A股上市

中国知网 https://www.cnki.net

公司公告处罚的4667条记录,本文删除了处置类型为“不予处罚”的样本7条和尚处于调查阶段的样本112条,得到4558条处罚记录。在此基础上,对处罚公告进行逐条梳理,确认公告中的违规行为明确指出“因年报相关原因被处罚”,且处罚原因为“虚构利润、虚列资产、虚假记载(误导性陈述)、重大遗漏(包括诉讼、担保和关联交易)”等内容,最终得到舞弊记录1448条。会计报表数据来自RESSET数据库,选择未进行会计更正前的年报披露数据,市场数据来自国泰安金融数据库(CSMAR),合并后共得到40 574条数据。1998年是现金流量表在中国首次披露的年份,考虑到对会计舞弊处罚存在时滞,研究期间截至2018年年底。表1报告了样本期内中国A股上市公司会计舞弊的年度分布情况,会计舞弊公司占比平均为3.57%,发生最多的年份是2016、2017和2018年,占比分别为5.54%、5.92%和5.26%,从2005年开始,会计舞弊比率总体呈现上升态势,这反映了会计舞弊持续扩张的趋势。

表1　　中国A股上市公司会计舞弊样本年度分布

年份	上市公司样本数	舞弊公司样本数	舞弊公司占比(%)
1998	829	28	3.38
1999	926	35	3.78
2000	1061	49	4.62
2001	1141	37	3.24
2002	1204	42	3.49
2003	1267	57	4.50
2004	1356	49	3.61
2005	1352	31	2.29
2006	1435	29	2.02
2007	1549	30	1.94
2008	1603	27	1.68
2009	1752	29	1.66
2010	2106	38	1.80
2011	2340	53	2.26
2012	2471	67	2.71
2013	2516	65	2.58
2014	2633	91	3.46
2015	2825	122	4.32
2016	3120	173	5.54
2017	3497	207	5.92
2018	3591	189	5.26
合计	40 574	1448	3.57

中国知网　https://www.cnki.net

（二）研究模型和实验设计

本文首先验证机器学习不依赖因子遴选而获得更高的预测准确性，将会计报表的全部科目都作为预测因子引入模型，共计331个。科目金额使用年度财务报表发生会计更正前首次披露的报表数字。同时，对比模型选用Bao *et al.*（2020）使用的14个会计比率（见文末附表A），便于研究结果比较，该比率组合在Cecchini *et al.*（2010）和Dechow *et al.*（2011）对会计舞弊识别指标的综述基础上形成，覆盖了国内外预测会计舞弊的主要财务特征（于李胜，2007；叶建芳等，2009；李春涛等，2016；叶钦华等，2022）。

本文将样本在时间轴上划分为训练期、验证期和测试期，使用训练期样本在验证期上调参寻优，再将训练期和验证期合并为总训练期，使用所得参数在总训练期上建立模型，在测试期上进行预测。验证期设为2年，总训练期应不少于10年。为避免前瞻性偏差，总训练期与测试期之间间隔两年时间，即舍去中间一年的样本，因为在测试期时点无法保证中间一年舞弊样本的可靠性。并且，为了充分发挥机器学习模型迭代修正的优势，实验设计使用滚动预测方法，每次预测各个窗口均向前滚动一年，不断重复“学习-训练-预测”过程。

测试期起始选定为2013年，这是考虑到从2013年开始，证券监管进行了执法程序的全面改革，广泛地将执法权力下放给其派出机构与证券交易所，增加交易所的执法人员编制，证监会开始更多地充当中央协调机构角色（Cao *et al.*，2021）。在会计舞弊的监管上，证券交易所实施信息披露直通车改革，对年报的监管重心转移为事后监管，这种“放松管制、加强监管”的理念对证券监管效果产生了明显影响（陈运森等，2019）。整个测试期为2013-2018年，共有6个预测窗口。如图2所示，以2013年测试期为例，对应的训练期为1998-2009年，验证期为2010-2011年，总训练期为1998-2011年。

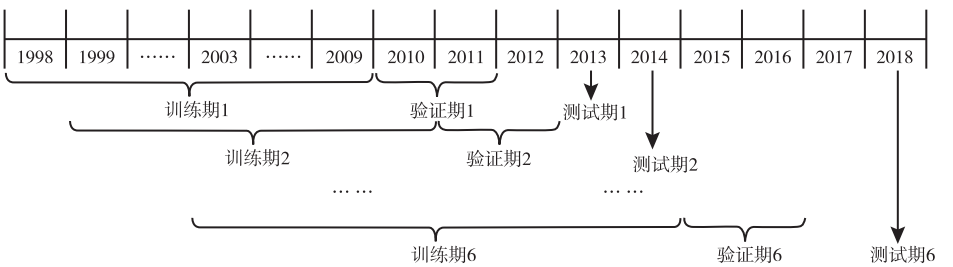

图2 实验设计与滚动预测

中国知网 https://www.cnki.net

(三)机器学习模型

如何充分发挥机器学习的理论优势是学术界关注的重点问题,考虑到机器学习"没有免费的午餐"理论(Wolpert,1996),不存在对所有样本都表现最佳的机器学习模型,本文引入近年来最为广泛应用的多个机器学习模型进行实验,包括了LASSO-Logit、SVM、RUSBoost、XGBoost、Random Forest、LightGBM、TabNet和NODE。这些模型的主要特点、优点和缺点如下表2所示。

表2 机器学习模型的分析和比较

预测模型	主要特点	优点	缺点
LASSO-Logit	结合Logit回归与L1正则化技术	自动进行特征选择,可解释性强	不太适用于非线性关系
SVM	通过寻找最优超平面最大化分类间隔	使用不同的核函数可以适应各种类型的数据	对数据噪声敏感,大规模和高维数据训练成本高
RUSBoost	集成学习方法,结合欠采样与AdaBoost处理不平衡问题	有效处理类别不平衡数据,提高分类性能	欠采样可能丢失重要信息
XGBoost	集成学习方法,基于梯度提升决策树模型,引入正则项防止过拟合	并行运算,训练速度快,能够处理缺失数据,有效处理大规模和高维数据	超参数调优过程复杂
Random Forest	集成学习方法,由多个决策树组成,使用Bagging方法构建	强大的分类性能,有效处理大规模和高维数据,对异常值和噪声稳健性较好	树的数量较多时,训练时间长
LightGBM	集成学习方法,在梯度提升框架上优化了训练速度,优化内存使用	高效的训练速度,有效处理大规模和高维数据	超参数调优过程复杂
TabNet	深度学习方法,基于自注意力机制的神经网络结构	专为结构化数据设计,能够自动学习处理特征	模型复杂性高,解释性差,训练时间长
NODE	深度学习方法,基于神经网络架构模拟决策树的集成学习方法	专为结构化数据设计,可以自动学习特征组合,减少特征工程需求	模型复杂性高,解释性差,训练时间长

(四)预测评价指标

参照现有研究(戴德宝等,2019;Bao *et al.*,2020;Bertomeu *et al.*,2021),本文使用AUC作为预测评价指标。AUC是ROC曲线所覆盖的标准化的阴影面积(见

中国知网 https://www.cnki.net

图3),ROC曲线是根据预测得到的舞弊概率序列,计算各个分类阈值的查全率和假正例率后获得,是对模型预测效果的二维描述,避免了样本不平衡和分类阈值的影响。AUC取值在0到1之间,AUC等于0.5表明ROC曲线相当于一条对角线,代表预测效果为随机猜测,AUC越接近1,则ROC曲线越趋近于点(0,1),投影面积越大,预测效果越好。

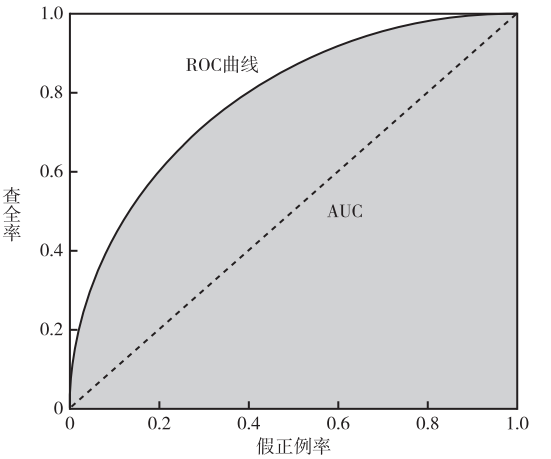

图3 ROC曲线与AUC

四 研究结果

(一)机器学习预测效果

表3 Panel A比较了使用会计比率@14、使用从会计比率还原的33个会计科目@33以及使用会计报表全部会计科目@331对会计舞弊滚动预测的结果①。三种预测条件下,各年预测的AUC数值均高于0.5,表明机器学习在中国会计舞弊预测领域是有效的。对比会计比率@14、会计科目@33和会计科目@331,可以看到8种机器学习模型中,会计科目@331预测AUC平均水平上是最高的。Panel B统计了8种机器学习模型滚动预测的AUC均值,可以看到会计科目@33预测相对会计比率@14预测的AUC均值更高,这与Bao *et al.*(2020)的发现一致②。8种机器学习模型使用会计科目@331相对使用会计比率@14预测的AUC均值提升12.22%③,包括使用会计科目@331相对使用会计科目@33预测的AUC均值提升5.92%,以及使用会计科目@33相对使用会计比率@14预测的AUC均值提升6.02%。

① 为了便于后文的表达,本文使用角标衡量了机器学习模型不同输入变量的差异,会计比率@14代表使用14个遴选的会计比率作为输入变量,会计科目@33代表从14个遴选会计比率还原得到的33个原始会计科目作为输入变量,会计科目@331代表会计报表全部331个原始会计科目作为输入变量。

② Bao *et al.*(2020)比较了会计比率还原的"会计科目@33"与使用报表全部"会计科目@331"预测的AUC,发现后者没有预测优势,这可能与研究对象差异有关,包括类不平衡程度差异、会计科目内涵差异、上市公司样本数量差异等。

③ 平均AUC提升=[(1.1583+1.0865+1.1322+1.1597+1.1190+1.1226+1.1009+1.0980)/8-1]×100%。

中国知网 https://www.cnki.net

其中,预测效果最好的Random Forest模型使用会计科目@331预测的AUC均值达到0.7173,相对使用会计比率@14提升11.90%,相对使用会计科目@33提升3.46%。XGBoost模型使用会计科目@331预测的AUC均值达到0.7095,仅次于Random Forest模型。

表3　　2013-2018年机器学习滚动预测AUC

Panel A:机器学习滚动预测AUC

预测因子	预测年份	LASSO-Logit	SVM	RUSBoost	XGBoost	Random Forest	LightGBM	TabNet	NODE
会计比率@14	2013	0.6057	0.6087	0.5888	0.6038	0.6569	0.6498	0.5871	0.5934
	2014	0.6235	0.5846	0.5883	0.5899	0.6299	0.5938	0.5344	0.6305
	2015	0.5370	0.5733	0.5692	0.5562	0.6101	0.5143	0.5294	0.5206
	2016	0.5277	0.5173	0.5923	0.5511	0.5803	0.5998	0.5385	0.5149
	2017	0.5389	0.5654	0.6449	0.6311	0.6325	0.6393	0.5177	0.5473
	2018	0.6433	0.6548	0.6255	0.7385	0.7362	0.7328	0.6596	0.6696
会计科目@33	2013	0.6240	0.5846	0.6844	0.6741	0.6747	0.6481	0.5748	0.5633
	2014	0.6496	0.6088	0.6336	0.6811	0.6995	0.6789	0.5445	0.6114
	2015	0.5747	0.5888	0.6145	0.6196	0.6545	0.6205	0.5792	0.5348
	2016	0.5993	0.5955	0.6199	0.6428	0.6526	0.6328	0.5309	0.5150
	2017	0.6104	0.5830	0.6782	0.6862	0.7143	0.6545	0.6076	0.5215
	2018	0.7721	0.6564	0.6966	0.7570	0.7643	0.7120	0.6505	0.6525
会计科目@331	2013	0.6504	0.6184	0.6904	0.7184	0.7318	0.6829	0.5891	0.5974
	2014	0.6525	0.5797	0.6854	0.6929	0.7386	0.6837	0.5736	0.6343
	2015	0.6077	0.5711	0.6268	0.6206	0.6716	0.6411	0.5974	0.6109
	2016	0.6841	0.6171	0.6303	0.6878	0.6517	0.6801	0.5857	0.5980
	2017	0.7114	0.7206	0.7218	0.7556	0.7345	0.7136	0.6301	0.6312
	2018	0.7204	0.7002	0.7313	0.7818	0.7757	0.7853	0.7302	0.7451

Panel B:2013-2018年机器学习滚动预测AUC均值

预测模型	会计比率@14	会计科目@33	会计科目@331	会计科目@331/会计比率@14	会计科目@331/会计科目@33
LASSO-Logit	0.5794	0.6384	0.6711	1.1583	1.0512
SVM	0.5840	0.6029	0.6345	1.0865	1.0524
RUSBoost	0.6015	0.6545	0.6810	1.1322	1.0405
XGBoost	0.6118	0.6768	0.7095	1.1597	1.0483
Random Forest	0.6410	0.6933	0.7173	1.1190	1.0346
LightGBM	0.6216	0.6578	0.6978	1.1226	1.0608
TabNet	0.5611	0.5813	0.6177	1.1009	1.0626
NODE	0.5794	0.5664	0.6362	1.0980	1.1232

说明:Panel B中会计科目@331/会计比率@14、会计科目@331/会计比率@33表示两种预测条件下AUC的比值。

中国知网　https://www.cnki.net

（二）预测因子的特征重要性

在8种不同的机器学习模型中，Random Forest使用会计比率@14和会计科目@331的预测效果均最好，AUC分别是0.6410和0.7173，显著高于0.5的随机猜测，这表明该模型对会计舞弊预测的迭代优化效果较好，因此，下面本文基于Random Forest模型对会计比率@14和会计科目@331的预测差异展开进一步的分析。

表4报告了Random Forest模型使用会计比率@14对会计舞弊滚动预测的特征重要性，观察Panel A 2013年特征重要性①前6个会计比率，能够发现其特征重要性在随后的5年中均发生下降，说明随时间发展它们的相对重要性减弱。很少观察到各年的特征重要性大于11或小于1，大部分会计比率@14的特征重要性在5到11之间，中位特

表4　　会计比率@14的特征重要性分析

Panel A：会计比率@14对会计舞弊滚动预测的特征重要性							
序号	会计比率	2013	2014	2015	2016	2017	2018
1	软资产比例	**10.41**	**10.86**	**10.17**	**9.84**	**10.94**	**9.03**
2	留存收益比例	**9.15**	**9.84**	**9.42**	**9.71**	8.73	8.38
3	现金销售率变动率	**10.93**	**9.10**	8.59	7.55	**9.40**	8.43
4	息税前利润比例	**9.50**	**9.42**	**9.28**	8.32	8.69	8.03
5	应收账款变动率	**9.52**	8.44	8.25	7.99	7.91	8.14
6	现金保证金变动率	**9.02**	8.84	8.35	7.89	7.42	7.64
7	账面市值比	6.20	6.76	7.40	7.40	8.52	7.97
8	折旧率指数	5.96	6.95	7.04	7.19	6.64	7.21
9	经营资本应计项变动率	5.74	6.43	7.14	7.42	6.63	7.00
10	存货变动率	6.63	6.31	6.52	7.32	6.10	7.15
11	ROA变动率	6.69	6.00	6.52	6.79	5.98	6.93
12	RSST应计项变动率	5.32	5.53	5.62	6.10	6.18	6.61
13	自由现金流变动率	4.73	5.23	5.42	6.07	6.39	6.82
14	是否再融资	0.14	0.20	0.22	0.35	0.40	0.58
Panel B：会计比率@14特征重要性的区间统计							
		2013	2014	2015	2016	2017	2018
	特征重要性>10	2	1	1	0	1	0
	特征重要性>9	6	4	3	2	2	1
	特征重要性>8	6	6	6	3	5	5

说明：为便于展示，Panel A中的特征重要性为原值的100倍，每年预测因子的特征重要性之和为100，后表同。为了直观展示趋势，Panel A对特征重要性大于9的值以黑体字显示。Panel B统计了Panel A中各个特征重要性区间内的会计比率数量。

① 特征重要性的原始取值范围在0到1之间，为便于展示，本文将特征重要性取值放大100倍处理。

中国知网 https://www.cnki.net

征重要性为8。Panel B对各年会计比率@14特征重要性情况进行了统计,可以看到,2015年前“特征重要性>10”的会计比率数量显著多于2015年后,特征重要性>9和特征重要性>8也呈现同样趋势,强解释力的因子解释效力降低,这说明经验研究的“红旗指标”可能会逐渐变得相对“普通”①,监管者可能需要投入更多的资源筛查和验证新的有指向意义的会计比率,从而降低监管效率。

Random Forest模型使用会计科目@331对2013-2018年会计舞弊进行滚动预测,按照6年累计特征重要性排序得到前40的会计科目,各年特征重要性数值如表5所示。可以发现,特征重要性前40的会计科目中,特征重要性>1的会计科目从2013年的25个减少到2018年的10个,说明不同会计科目对于预测的相对重要性容易发生变化。本文将会计比率@14还原为相关会计科目,共涉及33个科目(见文末附表A)。这些科目在特征重要性前40的会计科目中占据12个,其中特征重要性>1的数量从2013年的7个下降到2018年的1个,说明遴选会计比率@14更容易受到预测因子相对重要性变化的影响。

表5　　会计科目@331的特征重要性分析

会计科目	会计比率@14相关	会计更正频率前40	2013	2014	2015	2016	2017	2018
支付给职工以及为职工支付的现金			**1.49**	**1.36**	**1.45**	**1.57**	**1.25**	**1.17**
预付款项		√	**1.29**	**1.26**	**1.30**	**1.44**	**1.25**	**1.11**
其他应收款		√	**1.31**	**1.40**	**1.31**	**1.25**	**1.16**	**1.09**
支付的各项税费			**1.33**	**1.34**	**1.27**	**1.27**	**1.21**	**1.09**
加:营业外收入			**1.22**	**1.25**	**1.21**	**1.31**	**1.13**	**1.03**
应付职工薪酬			**1.14**	**1.14**	**1.18**	**1.29**	**1.20**	**1.13**
资本公积			**1.28**	**1.23**	**1.14**	**1.13**	**1.11**	**1.06**
无形资产			**1.26**	**1.20**	**1.20**	**1.17**	**1.05**	0.94
实收资本(或股本)			**1.15**	**1.18**	**1.25**	**1.06**	**1.07**	**1.04**
盈余公积	√	√	0.94	**1.04**	**1.06**	**1.09**	**1.03**	**1.10**
收到其他与经营活动有关的现金			**1.01**	**1.08**	**1.06**	**1.05**	**1.04**	0.99

① 一些先前特征重要性高的会计比率逐渐变得“普通”,从相对重要性的角度本文推断,这可能是公司规避行为导致。特征重要性的局限在于,它主要展示指标之间相对重要性的此消彼长,无法对全部指标集合的整体解释力度做进一步分析。因此,本文不能了解公司的规避行为影响了当前会计比率@14之外的其他会计比率,还是只影响会计比率@14中先前没那么“突出”的会计比率。

中国知网 https://www.cnki.net

（续表）

会计科目	会计比率[@14]相关	会计更正频率前40	2013	2014	2015	2016	2017	2018
应收账款	√	√	**1.18**	**1.05**	**1.05**	0.99	0.97	0.99
长期股权投资	√		**1.11**	**1.03**	**1.04**	**1.06**	**1.02**	0.94
少数股东权益		√	**1.03**	**1.06**	**1.07**	**1.01**	**1.03**	0.97
货币资金	√		**1.09**	**1.03**	**1.01**	**1.00**	0.99	0.97
营业税金及附加		√	**1.05**	**1.11**	**1.08**	**1.00**	0.93	0.85
应收票据及应收账款			**1.04**	**1.06**	**1.02**	0.98	0.92	0.97
少数股东损益		√	**1.10**	**1.05**	**1.02**	**1.01**	0.91	0.88
财务费用	√	√	**1.07**	**1.05**	**1.03**	**1.02**	0.92	0.88
期末现金及现金等价物余额			**1.02**	**1.02**	**1.01**	0.91	0.99	0.98
营业收入	√	√	**1.09**	**1.03**	**1.02**	**1.03**	0.91	0.86
营业成本	√	√	**1.08**	**1.03**	**1.04**	0.97	0.94	0.87
营业总收入			**1.06**	**1.03**	**1.03**	0.94	0.92	0.89
固定资产	√	√	0.94	0.99	**1.00**	**1.01**	0.96	0.92
销售商品、提供劳务收到的现金			0.97	**1.03**	**1.01**	**1.02**	0.90	0.84
购建固定资产、无形资产和其他长期资产支付的现金			0.96	0.93	0.91	0.95	0.97	0.93
支付其他与经营活动有关的现金			**1.03**	0.99	0.91	0.91	0.89	0.90
应交税费	√	√	**1.02**	**1.00**	0.97	0.90	0.90	0.84
归属母公司股东权益合计		√	0.99	0.98	0.98	0.91	0.89	0.87
减:营业外支出		√	0.90	0.88	0.92	0.91	0.99	**1.00**
应付账款	√	√	0.97	**1.00**	**1.00**	0.88	0.86	0.85
营业总成本			0.92	0.96	0.97	0.99	0.87	0.83
加:期初现金及现金等价物余额			0.90	0.98	0.98	0.88	0.87	0.89
未分配利润	√	√	0.97	0.89	0.93	0.94	0.86	0.85
负债合计	√	√	0.98	0.95	0.94	0.88	0.84	0.82
经营活动现金流入小计			0.96	0.98	0.92	0.82	0.86	0.83
经营活动现金流出小计			0.98	0.96	0.92	0.85	0.83	0.82
管理费用		√	**1.05**	0.95	0.93	0.80	0.81	0.79
经营活动产生的现金流量净额			0.85	0.87	0.90	0.87	0.92	0.94
应付票据			0.91	0.89	0.93	0.97	0.86	0.78

说明:本表仅展示会计科目[@331]特征重要性数值前40的结果。为了直观展示趋势,本表对特征重要性大于1的值以黑体字表示。下同。

中国知网 https://www.cnki.net

表6报告了Random Forest模型使用会计科目[@331]滚动预测后,由会计比率[@14]还原的33个会计科目的特征重要性表现。33个会计科目加总的特征重要性从2013年的24.64降低到2018年的21.71,说明会计科目[@33]的相对重要性下降,这是会计科目[@33]预测AUC小于会计科目[@331]的重要原因。此外,会计科目[@33]中属于会计更正频率前40的会计科目(见附表B)有18个,特征重要性>1的科目中仅有2个不属于会计更正频率前40的会计科目,考虑到会计更正被认为与会计舞弊密切关联,本文加总了18个会计更正科目的特征重要性,发现它们也从2013年的17.36下降到2018年的15.36,表现出会计科目[@33]对于会计舞弊相对重要性的下降。

表6　　会计科目[@33]的特征重要性分析

会计科目	会计更正频率前40	2013	2014	2015	2016	2017	2018
盈余公积	√	0.94	**1.04**	**1.06**	**1.09**	**1.03**	**1.10**
应收账款	√	**1.18**	**1.05**	**1.05**	0.99	0.97	0.99
长期股权投资		**1.11**	**1.03**	**1.04**	**1.06**	**1.02**	0.94
货币资金		**1.09**	**1.03**	**1.01**	**1.00**	0.99	0.97
财务费用	√	**1.07**	**1.05**	**1.03**	**1.02**	0.92	0.88
营业收入	√	**1.09**	**1.03**	**1.02**	**1.03**	0.91	0.86
营业成本	√	**1.08**	**1.03**	**1.04**	0.97	0.94	0.87
固定资产	√	0.94	0.99	**1.00**	**1.01**	0.96	0.92
应交税费	√	**1.02**	**1.00**	0.97	0.90	0.90	0.84
应付账款	√	0.97	**1.00**	**1.00**	0.88	0.86	0.85
未分配利润	√	0.97	0.89	0.93	0.94	0.86	0.85
负债合计	√	0.98	0.95	0.94	0.88	0.84	0.82
减:所得税费用	√	0.92	0.91	0.87	0.85	0.93	0.83
存货	√	0.90	0.93	0.91	0.85	0.83	0.80
营业利润	√	0.91	0.86	0.86	0.90	0.86	0.82
净利润	√	0.92	0.83	0.85	0.91	0.87	0.81
市值		0.88	0.94	0.94	0.80	0.82	0.78
所有者权益(或股东权益)合计	√	0.91	0.89	0.87	0.82	0.83	0.82
资产总计	√	0.82	0.91	0.91	0.89	0.80	0.81
流动负债合计	√	0.98	0.91	0.89	0.77	0.79	0.74
固定资产折旧		0.86	0.83	0.85	0.75	0.86	0.82
在建工程		0.95	0.89	0.85	0.72	0.72	0.74
流动资产合计	√	0.76	0.83	0.84	0.72	0.77	0.75
长期借款		0.55	0.52	0.56	0.58	0.50	0.49
一年内到期的非流动负债		0.51	0.54	0.48	0.41	0.43	0.43
工程物资		0.57	0.55	0.54	0.48	0.36	0.27

中国知网　https://www.cnki.net

（续表）

会计科目	会计更正频率前40	2013	2014	2015	2016	2017	2018
交易性金融资产		0.36	0.37	0.31	0.24	0.27	0.22
可供出售金融资产		0.12	0.14	0.15	0.18	0.25	0.33
应付债券		0.17	0.17	0.20	0.22	0.18	0.20
持有至到期投资		0.05	0.05	0.05	0.11	0.07	0.07
增发配股		0.04	0.05	0.05	0.04	0.05	0.05
长期债券发行		0.02	0.03	0.04	0.03	0.03	0.04
优先股		0.00	0.00	0.00	0.00	0.00	0.00
合计		24.64	24.24	24.11	23.04	22.42	21.71

（三）机器学习预测的稳健性检验

1. 更换预测评价指标为NDCG@k和PRC

NDCG@k是一种广泛用于评价推荐算法排序结果的指标，在理论上被证明是有效的（Wang *et al.*，2013），最早由Bao *et al.*（2020）引入会计舞弊预测领域。会计舞弊发生率较低，由于公共资源限制，会计舞弊预测仅能关注高舞弊风险公司的预测效果，这与使用搜索引擎时仅关注排序靠前的推荐结果相类似，因此适用于NDCG@k指标进行评价。

NDCG@k是DCG@k标准化后的结果，DCG@k的计算逻辑是：将上市公司按舞弊预测概率从大到小排序，对排名靠前的公司样本赋予更大的权重，排名靠前的公司的预测越准确，则DCG@k越高。与AUC一样，NDCG@k的取值范围在0到1之间，NDCG@k越大代表预测效果越好。

NDCG@k具体计算方法如下，首先，计算DCG@k：

$$DCG@k = \sum_{i=1}^{k} \frac{2^{rel_i} - 1}{\log_2(i+1)} \tag{1}$$

其中，若排名第i的公司是真实舞弊，则rel_i为1，否则为0；k是需关注的公司数量；$\log_2(i+1)$是折现公式，i越小，折现权重越大。得到DCG@k后，还需计算理想的DCG@k，理想的DCG@k假定所有真实的舞弊样本均排在队列前端。使用理想的DCG@k对DCG@k做标准化处理，得到预测评价指标NDCG@k。由于2013-2018年测试期间的舞弊公司占比均不超过6%（见表1），本文的k值设定为测试期每年公司数量的6%。

此外，PRC指标（Precision-Recall Curve，精确率-召回率曲线）是一种用于评估分类模型性能的指标，特别适用于不平衡数据集（Davis and Goadrich，2006）。它与ROC曲线类似，绘制了不同阈值下精确率（precision）和召回率（recall）之间的关系，精确率

中国知网 https://www.cnki.net

表示在预测为舞弊的样本中实际为舞弊的比例,而召回率表示在所有实际为舞弊的样本中被正确预测为舞弊的比例。通过计算曲线所覆盖的标准化面积,可以判断模型的预测性能。PRC的取值范围在0到1之间,PRC越大代表预测效果越好。

表7的Panel A报告了预测评价指标更换为NDCG@k和PRC的结果,分年度的预测结果报告于附表C。可以看到,与AUC评价指标相同的是,大多数机器学习模型中使用会计科目$^{@331}$的预测效果均优于使用会计比率$^{@14}$和会计科目$^{@33}$,这与表3的发现一致。不同的是,XGBoost模型的预测效果在NDCG@k和PRC指标下优于Random Forest模型。

表7　　机器学习预测的稳健性检验

Panel A:更换预测评价指标为NDCG@k和PRC

预测指标	AUC			PRC			NDCG@k		
预测模型	会计比率$^{@14}$	会计科目$^{@33}$	会计科目$^{@331}$	会计比率$^{@14}$	会计科目$^{@33}$	会计科目$^{@331}$	会计比率$^{@14}$	会计科目$^{@33}$	会计科目$^{@331}$
LASSO-Logit	0.5794	0.6384	0.6711	0.0782	0.0823	0.0930	0.1388	0.1353	0.1507
SVM	0.5840	0.6029	0.6345	0.0733	0.0670	0.0757	0.1127	0.1039	0.1085
RUSBoost	0.6015	0.6545	0.6810	0.0781	0.0911	0.1000	0.1177	0.1567	0.1696
XGBoost	0.6118	0.6768	0.7095	0.0822	0.1049	0.1219	0.1244	0.1870	0.2049
Random Forest	0.6410	0.6933	0.7173	0.0837	0.1029	0.1069	0.1121	0.1697	0.1708
LightGBM	0.6216	0.6578	0.6978	0.0871	0.0967	0.1043	0.1402	0.1667	0.1694
TabNet	0.5611	0.5813	0.6177	0.0651	0.0589	0.0730	0.0945	0.0636	0.1024
NODE	0.5794	0.5664	0.6362	0.0752	0.0655	0.0752	0.1169	0.1198	0.1029

Panel B:更换预测因子后的AUC均值

预测模型	会计比率$^{@14}$+会计科目$^{@33}$	会计科目$^{@14}$+会计科目$^{@331}$	会计科目$^{@331}$行业调整额	会计科目$^{@331}$年度变化率	会计科目$^{@331}$
LASSO-Logit	0.6372	0.6642	0.6341	0.5398	0.6711
SVM	0.6069	0.6206	0.6326	0.5428	0.6345
RUSBoost	0.6325	0.6715	0.6534	0.5950	0.6810
XGBoost	0.6638	0.6906	0.6895	0.6571	0.7095
Random Forest	0.6899	0.7016	0.6877	0.6505	0.7173
LightGBM	0.6584	0.6815	0.6730	0.6576	0.6978
TabNet	0.5730	0.5993	0.5886	0.5579	0.6177
NODE	0.5485	0.6214	0.6235	0.5331	0.6362

说明:Panel B展示了更换预测因子的AUC结果均值,其中行业调整额=(原值-行业中位数)/行业中位数,年度变化率=(当年金额-上一年金额)/|上一年金额|。

中国知网　https://www.cnki.net

2. 更换会计舞弊预测因子

会计报表的可比性是会计舞弊判断的重要依据，包括行业内的横向可比性和年度间的纵向可比性。例如，监管机构会利用同行业公司横向比较的方法审核公司业绩真实性（梅蓓蕾等，2021）。考虑到从会计报表可比性得到舞弊预测，本文将预测因子从会计报表本期金额更换为行业调整额和年度变化率。并且，为了避免将会计比率还原为会计科目，可能丢失会计比率蕴含的勾稽关系信息，本文还将预测因子分别更换为会计比率$^{@14}$+会计科目$^{@33}$，会计科目$^{@14}$+会计科目$^{@331}$，重新运行表3模型。

表7 Panel B报告了更换预测因子为会计科目$^{@331}$的行业调整额、会计科目$^{@331}$的年度变化率、会计比率$^{@14}$+会计科目$^{@33}$、会计科目$^{@14}$+会计科目$^{@331}$的预测结果，可以发现同样是会计科目$^{@331}$的预测效果最好，这些与表3的发现相一致。总体上，稳健性检验支持使用会计科目$^{@331}$预测优于遴选的会计比率$^{@14}$及其还原的会计科目$^{@33}$的结论。

3. 其他稳健性检验

除此以外，本文进行的其他稳健性测试包括：为了避免财政部2007年颁布执行新的《企业会计准则》这一重要会计制度对研究结论的影响，本文调整研究样本的区间为2007-2021年，避开会计制度变化对研究结论的影响，使用AUC作为预测评价指标，结果报告于附表D，预测因子为会计科目$^{@331}$时表现最好，与表3的发现一致。

考虑到会计舞弊界定可能对本文结论的影响，本文借鉴了洪荭等（2012）、叶康涛和刘金洋（2021）与叶钦华等（2022）的研究，调整会计舞弊的样本范围，剔除因“重大遗漏”与“误导性陈述”等原因而受到处罚的样本，调整后的样本年度分布情况见附表E Panel A，结果报告于附表E Panel B，预测因子为会计科目$^{@331}$时表现最好，与表3的发现保持一致。

考虑到特征重要性依赖于使用的机器学习模型，本文补充使用了表3中预测效果最好的Random Forest模型、XGBoost模型，使用SHAP（SHapley Additive exPlanations，沙普利可加性特征解释方法）重新计算模型的特征重要性。使用会计科目$^{@331}$对2013-2018年会计舞弊进行滚动预测，附表F和附表G报告了SHAP特征重要性取值前40的会计科目，可以发现，会计科目$^{@331}$机器学习$^{@}$Random Forest（会计科目$^{@331}$机器学习$^{@}$XGBoost）的SHAP特征重要性大于2的会计科目，从2013年的5个（8个），下降到2018年的3个（2个），这与本文表5的发现基本一致①。

① 限于篇幅，此处略去报告，对此感兴趣的读者可访问《世界经济》网站（www.jweonline.cn）2024年第11期在线期刊中本文补充材料附表D、E、F、G。

中国知网 https://www.cnki.net

五　进一步研究

(一)抽样监管与机器学习预测

加大执法力度,提高对违规行为处罚的确定性和严厉性有助于遏制会计舞弊。然而,会计舞弊的调查和取证需要付出高昂的时间和执法成本,将会计舞弊调查范围扩大到全部被监管公司不具有现实操作性,也不具备经济性。"随机抽检"是一种降低公共监管成本,提高执法效率的有效手段(薛澜和张帆,2016),有助于压缩寻租空间,缓解潜在的选择性执法问题(滕飞等,2022)。2015年8月国务院发布了《国务院办公厅关于推广随机抽查规范事中事后监管的通知》(以下简称《通知》),开始在市场监管领域各部门的日常监管中推行随机抽查制度。根据随机抽查的制度设计,监管部门要制定随机抽查事项清单,随机抽取检查对象、随机选派执法检查人员,并及时向社会公开抽查和检查结果,即"双随机、一公开"。根据2015年11月证监会公布的首份《中国证监会随机抽查事项清单》,上市公司抽检制度由各派出机构根据实际情况自行确定使用摇号等抽查方式,抽查频次为1次/年,抽查比例为5%。

法律的威力来源于更高的处罚概率或更严格的处罚力度。机器学习对会计舞弊的预测有助于提高随机抽检处罚概率,非遴选预测因子不形成新的市场"红旗"指标,符合国务院于2019年2月印发的《国务院关于在市场监管领域全面推行部门联合"双随机、一公开"监管的意见》中提出的要求,即"在抽查机制设计、信息公开和结果运用、职责界定等方面做出修改和完善",具有现实操作性。基于此,本文依据"双随机、一公开"抽检原则模拟了随机抽检下的会计舞弊的检出策略,对比分析机器学习抽检策略的预测优势。

表8报告了不同抽检策略下会计舞弊的检出情况,5%的抽检阈值下机器学习@Random Forest检出数量均显著大于随机抽检,总体高出217.5%(127/40-1)。逐步放宽抽检阈值,机器学习@Random Forest大比例的检出优势保持不变,体现了将机器学习预测引入随机抽检制度的优势。

如表8所示,扩大抽检比例能够提高舞弊公司的检出数量,这带来一个思考:当前抽检比例是否足以遏制会计舞弊?考虑到人员编制、专业水平、预算控制和执法程序等多个方面,需要充分权衡执法资源扩张决策。本文引入抽检阈值和查全率展开对这个问题的讨论。抽检阈值是抽检数量占全部上市公司的比例,查全率是抽检检出的舞弊公司占全部舞弊公司的比例。抽检阈值越高,执法成本越大;查全率越高,市场威慑力越

中国知网　https://www.cnki.net

表8 抽检策略与机器学习预测 （件，%）

抽检策略	2013 数量	2013 占比	2014 数量	2014 占比	2015 数量	2015 占比	2016 数量	2016 占比	2017 数量	2017 占比	2018 数量	2018 占比	合计 数量
随机抽检5%	3	4.76	4	4.49	6	5.22	8	4.82	10	5.03	9	4.95	40
随机抽检6%	4	6.35	5	5.62	7	6.09	10	6.02	12	6.03	11	6.04	49
随机抽检7%	4	6.35	6	6.74	8	6.96	11	6.63	13	6.53	12	6.59	54
随机抽检8%	5	7.94	7	7.87	9	7.83	13	7.83	16	8.04	14	7.69	64
随机抽检9%	6	9.52	8	8.99	10	8.70	14	8.43	17	8.54	16	8.79	71
随机抽检10%	6	9.52	9	10.11	11	9.57	16	9.64	19	9.55	18	9.89	79
机器学习5%	17	26.98	13	14.61	16	13.91	13	7.83	32	16.08	36	19.78	127
机器学习6%	20	31.75	17	19.10	20	17.39	15	9.04	37	18.59	42	23.08	151
机器学习7%	21	33.33	19	21.35	22	19.13	19	11.45	42	21.11	49	26.92	172
机器学习8%	23	36.51	22	24.72	23	20.00	19	11.45	49	24.62	51	28.02	187
机器学习9%	25	39.68	25	28.09	28	24.35	22	13.25	53	26.63	58	31.87	211
机器学习10%	25	39.68	29	32.58	29	25.22	24	14.46	56	28.14	62	34.07	225

说明：表中数量代表检出舞弊数量，占比代表年度舞弊占比。本表实验参考滕飞等（2022）的研究，剔除上年度被立案调查的公司（2013-2018年分别剔除28、44、65、60、55、64家公司），这些公司被认为存在较大舞弊风险，因此无需预测；随机抽检是不放回抽样，且剔除3年内已被抽检过的公司样本；随机抽检重复1000次，检出舞弊数量取1000次均值，年度舞弊占比是检出舞弊数量占年度舞弊数量的比例。图4与表10同。

强。图4模拟了随机抽检与机器学习@Random Forest抽检策略下，对于执法资源扩张的权衡分析，展示了不同抽检策略下设定的抽检阈值对查全率的影响。在5%的抽检阈值上，随机抽检与机器学习@Random Forest抽检策略分别检出4.91%和15.60%的舞弊公司，在查全率指标上机器学习@Random Forest抽检策略始终优于随机抽检，两种策略的查全率均随着执法资源的扩张而增加，并且机器学习@Random Forest抽检策略的增加速度更快。

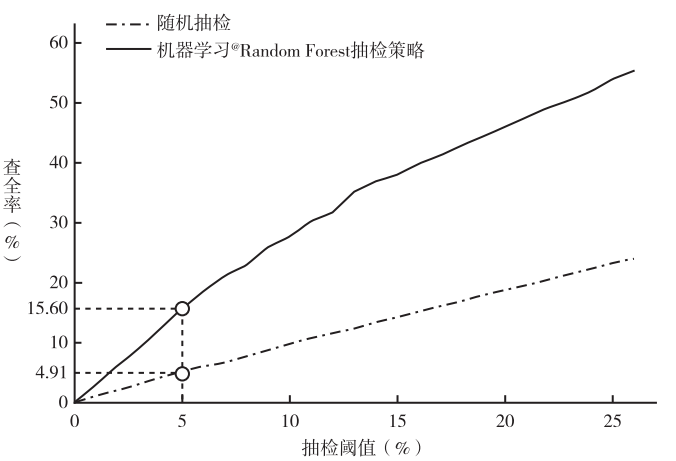

图4 不同抽检策略的执法资源扩张效果

中国知网 https://www.cnki.net

此外,为了了解机器学习对于重大舞弊案例的预测效果,本文基于证监会每年总结通报的典型违法案例,分别使用Logit回归(会计比率@14)和机器学习@Random Forest(会计科目@331)两种不同的方法,比较它们对2013-2018年处罚金额最大的10起案例的预测效果。

首先,根据预测模型计算某一年度全部上市公司的舞弊概率;其次,将全部上市公司按舞弊概率由大到小排序;最后,找到重大舞弊案例在已排好序列中的百分比位置,即为模型对该案例的预测阈值。阈值越小则表示模型识别舞弊公司所需的抽样范围越小,预测能力越强。如表9所示,2013-2018年处罚金额最大的10起案例中,除獐子岛案例未能表现出机器学习的预测优势外,机器学习@Random Forest在识别其他9起案件时均有显著的预测优势,表现为预测阈值均值30.33%,显著小于Logit回归的预测阈值均值73.76%,预测阈值降低58.89%,这表明绝大多数情况下,机器学习在预测重大会计舞弊案例时抽样范围更小,监管的经济性更强。

表9　　重大舞弊案例与机器学习预测

序号	公司名称	通报年份	首次舞弊年份	会计比率@14 Logit回归预测阈值(%)	会计科目@331 机器学习@Random Forest预测阈值(%)
1	保千里	2019	2015	80.40	1.56
2	东方金钰	2020	2016	21.79	4.87
3	康得新	2020	2015	90.53	7.12
4	山西三维	2018	2014	90.97	8.74
5	广州浪奇	2021	2018	37.88	20.66
6	康美药业	2020	2016	95.17	33.91
7	宜华生活	2021	2016	89.16	34.33
8	獐子岛	2020	2016	33.00	36.57
9	长生生物	2018	2015	99.13	77.49
10	雅百特	2017	2015	99.61	78.02

(二)处罚时滞与机器学习预测

中国资本市场存在违规稽查过程冗长迟缓的现象(郦金梁等,2020)。通过计算年报公告到会计处罚公告的时间间隔,本文统计了上市公司会计舞弊的处罚时滞,如图5所示,1998-2018年会计舞弊处罚时滞的均值为1071天,中位数为874天,处罚时

中国知网 https://www.cnki.net

滞广泛分布于1到4年,处罚时滞在2年以上的占比约60%,处罚时滞分布存在“长尾”现象,最长甚至达到16年。漫长的处罚时滞严重损害了执法威慑力,本文从监管资源配置和约束角度讨论机器学习对于改善处罚时滞的优势。

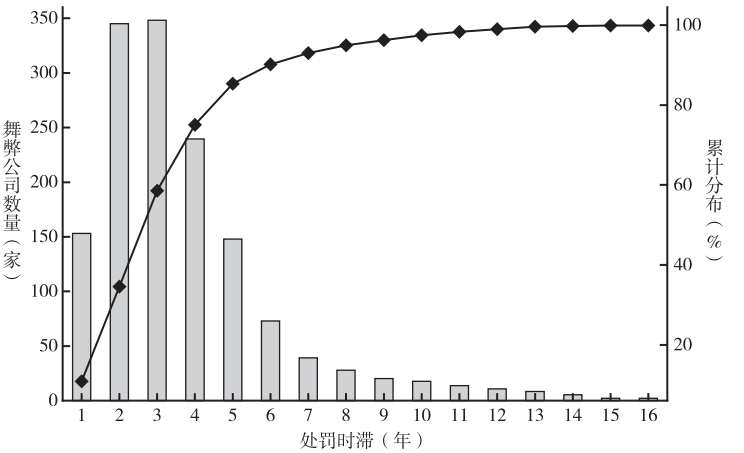

图5 会计舞弊的处罚时滞

会计舞弊的处罚时滞主要由两个时段构成,线索发现时段和调查取证时段(如图6所示),根据2013年8月证监会发布的《关于进一步加强稽查执法工作的意见》第十五条规定,“提高案件查办效率,案件调查审理周期原则上不得超过一年,确需延长办理期限的,应报会领导审批”,中国资本市场会计舞弊调查取证的时间在一年左右,本文重点观察一年期会计舞弊的处罚情况。

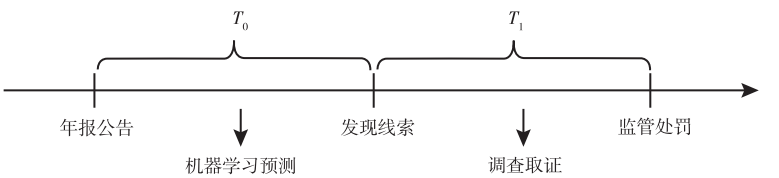

图6 会计舞弊检测与处罚流程

表10报告了机器学习@Random Forest模型对于缩短会计处罚时滞的影响。Panel A中,会计报表公告1年内处罚的公司数量(列3)大大超过《通知》中随机抽检的发现能力(列1),说明当前会计舞弊发现的重要路径是对由多途径获知的舞弊线索的判

中国知网 https://www.cnki.net

断、追踪和调查,随机抽检[@5%]发挥补充作用。本文对照了机器学习检出的具体公司(列2)和会计报表公告后1年内处罚的具体公司(列3),并报告两者重合的公司数量(列4)。在此基础上,本文估算机器学习的检出提升,一个稳健的假设是随机抽检发现的舞弊公司不在当年处罚的公司名单中,也不在机器学习检出的公司名单中,那么机器学习预测的补充效应等于机器学习检出公司排除重合公司(列4)和随机抽检公司(列1),如列(5)所示,其提升比例见列(6)。总体上,机器学习将1年内发现的会计舞弊数量提升58.33%,有助于缩短会计舞弊的处罚时滞。

表10　　机器学习预测对会计舞弊处罚时滞的影响

Panel A:机器学习预测的补充效应与会计舞弊处罚时效性

	抽检阈值5%		报告公告后1年内处罚的公司数量	列(2)和列(3)重合公司数量	机器学习[@]Random Forest补充效应	
	随机抽检	机器学习[@]Random Forest			提升数量(2)-(4)-(1)	提升比例(5)/(3)
年份	(1)	(2)	(3)	(4)	(5)	(6)
2013	3	17	3	0	14	466.67%
2014	4	13	7	1	8	114.29%
2015	6	16	9	1	9	100.00%
2016	8	13	20	0	5	25.00%
2017	10	32	42	7	15	35.71%
2018	9	36	39	8	19	48.72%
合计	40	127	120	17	70	58.33%

Panel B:机器学习抽检阈值与会计舞弊处罚时效性

	机器学习[@]Random Forest						报表公告后1年内处罚的公司数量
年份	抽检阈值5%	抽检阈值6%	抽检阈值7%	抽检阈值8%	抽检阈值9%	抽检阈值10%	
2013	17	20	21	23	25	25	3
2014	13	17	19	22	25	29	7
2015	16	20	22	23	28	29	9
2016	13	15	19	19	22	24	20
2017	32	37	42	49	53	56	42
2018	36	42	49	51	58	62	39

Panel B报告了使用会计科目[@331]机器学习[@]Random Forest在5%~10%抽检阈值下的检出数量,本文假定证监会《关于进一步加强稽查执法工作的意见》的要求得到了

中国知网 https://www.cnki.net

有效执行,那么机器学习检出的会计舞弊公司受到查处的时间均在1年内。以5%抽检阈值为例,可以发现2016、2017、2018年机器学习检出的会计舞弊公司数量(13家、32家、36家),少于真实情况下会计报告公告后1年内处罚的公司数量(20家、42家、39家)。逐步放大机器学习抽检阈值,结果发现当阈值放大到9%,2013-2018年每年机器学习检出的会计舞弊公司数量都高于真实情况下1年内被查处的会计舞弊公司数量,由此本文得到结论,当执法资源满足9%及以上的抽检阈值需求时,机器学习检出能力已经优于当前资本市场舞弊线索的收集力量。

六 结论和政策启示

本文基于1998-2021年上市公司年度财务报表和会计舞弊的数据,分析了非遴选因子条件下机器学习对于改善中国资本市场会计舞弊治理的优势和潜力。研究发现:(1)在未遴选会计科目的情况下,8种主流机器学习模型的预测准确性均显著优于基于遴选会计比率的模型,AUC平均提升12.22%。其中,Random Forest预测效果最好,AUC达到0.7173;(2)遴选会计比率由33个会计科目组成,这些科目在分年度的滚动预测中,特征重要性大于1的数量从最初的7个减少到1个;在特征重要性排序前40的会计科目中,遴选会计比率相关的科目只有12个,且绝大多数属于年报会计差错更正最频繁的40个科目,表明市场存在针对遴选会计比率的操纵和规避行为;(3)依据国务院“双随机、一公开”制度设定的抽检策略,非遴选机器学习检出的会计舞弊数量显著高于随机抽检,最高超出217.5%;对于测试期间排名前10的重大舞弊案例,机器学习降低抽检阈值58.89%;由于60%以上的会计舞弊在年报公告两年以后被发现,本文进一步比较和验证了机器学习对于缩短舞弊处罚时滞、提高舞弊发现数量的积极作用,在会计舞弊发生当年可以将发现数量提升58.33%。上述研究发现,在更换预测评价指标、更换预测因子、更换样本区间、更换舞弊样本范围和更换特征重要性计算方法等稳健性检验中,结论均保持了一致。

由于执法资源有限和信息不对称,会计舞弊行为难以被及时发现,导致公司会计舞弊的预期收益上升,推动市场舞弊行为增加。本文针对中国资本市场会计舞弊数量快速增加的问题,从提高会计舞弊发现的准确性和及时性角度,探讨了机器学习工具在改善执法效率和降低经理人逆向选择方面的积极意义。围绕提高监管效率和增强市场威慑,本文的研究成果为改善中国资本市场的会计舞弊治理提供了重要启示:

第一,推进监管科技化,构建以机器学习为核心的智能监管系统。本文的研究表

中国知网 https://www.cnki.net

明,机器学习模型在会计舞弊预测中的表现显著优于遴选会计比率等监管方法,监管机构应积极推动监管科技化,利用机器学习技术构建智能监管系统。该系统通过“学习-训练-预测”的迭代修正模式,快速适应市场变化,提高会计舞弊识别的准确性和效率。具体措施包括:引入和关注新的机器学习算法,持续迭代模型以适应资本市场环境和公司行为特征的变化,实现对会计舞弊的高效预警。

第二,优化公共执法资源配置,缩短案件的处理周期。机器学习技术能够显著降低发现会计舞弊公司的阈值,减少案件的处罚时滞。监管机构应利用这一优势,优化执法资源配置,集中力量对高风险公司进行深入调查,缩短会计舞弊案件的处理周期。建立基于机器学习预测的风险评估系统,实时监控市场变化,及时发现潜在的会计舞弊行为,并迅速采取相应的执法行动,通过缩短处罚时滞,提升会计舞弊治理的效率和威慑力。

第三,优化“双随机、一公开”抽检制度,提升执法精准度。本文研究验证了机器学习在优化抽检制度中的应用潜力。监管机构可基于机器学习模型的预测结果,动态调整抽查阈值和抽查频率,以确保高风险公司得到重点监管。同时,建立动态调整机制,确保资源有效配置与执法精准度的提高。这不仅能提升重大会计舞弊案件的检出率,还能有效减少选择性执法现象。

参考文献:

白云霞、王亚军、吴联生(2005):《业绩低于阈值公司的盈余管理——来自控制权转移公司后续资产处置的证据》,《管理世界》第5期。

蔡海静、汪祥耀、谭超(2017):《高送转、财务业绩与大股东减持规模》,《会计研究》第12期。

陈云松、吴晓刚、胡安宁、贺光烨、句国栋(2020):《社会预测:基于机器学习的研究新范式》,《社会学研究》第3期。

陈运森、邓祎璐、李哲(2019):《证券交易所一线监管的有效性研究:基于财务报告问询函的证据》,《管理世界》第3期。

陈运森、袁薇、李哲(2021):《监管型小股东行权的有效性研究:基于投服中心的经验证据》,《管理世界》第6期。

戴德宝、兰玉森、范体军、赵敏(2019):《基于文本挖掘和机器学习的股指预测与决策研究》,《中国软科学》第4期。

耿建新、肖泽忠(2002):《报表收益与现金流量数据之间关系的实证分析——信息不实公司的预警信号》,《会计研究》第12期。

洪荭、胡华夏、郭春飞(2012):《基于GONE理论的上市公司财务报告舞弊识别研究》,《会计研究》第8期。

李春涛、赵一、徐欣、李青原(2016):《按下葫芦浮起瓢:分析师跟踪与盈余管理途径选择》,《金融研究》

中国知网 https://www.cnki.net

第4期。

李增福、董志强、连玉君(2011):《应计项目盈余管理还是真实活动盈余管理? ——基于我国2007年所得税改革的研究》,《管理世界》第1期。

郦金梁、吴谣、雷曜、黄燕婷(2020):《有效预警上市公司违规的递延所得税异动指标和人工智能模型》,《金融研究》第8期。

刘少波、马超(2016):《经理人异质性与大股东掏空抑制》,《经济研究》第4期。

刘云菁、伍彬、张敏(2022):《上市公司财务舞弊识别模型设计及其应用研究——基于新兴机器学习算法》,《数量经济技术经济研究》第7期。

陆建桥(1999):《中国亏损上市公司盈余管理实证研究》,《会计研究》第9期。

吕成龙(2018):《证监会行政调查制度的解构与重述》,《证券市场导报》第5期。

梅蓓蕾、郭雪寒、叶建芳(2021):《问询函的溢出效应——基于盈余管理视角》,《会计研究》第6期。

钱爱民、朱大鹏(2020):《财务报告文本相似度与违规处罚——基于文本分析的经验证据》,《会计研究》第9期。

钱苹、罗玫(2015):《中国上市公司财务造假预测模型》,《会计研究》第7期。

滕飞、夏雪、辛宇(2022):《证监会随机抽查制度与上市公司规范运作》,《世界经济》第8期。

王红建、李青原、邢斐(2014):《金融危机、政府补贴与盈余操纵——来自中国上市公司的经验证据》,《管理世界》第7期。

王化成、曹丰、叶康涛(2015):《监督还是掏空:大股东持股比例与股价崩盘风险》,《管理世界》第2期。

吴东辉(1999):《中国上市公司应计项目选择的实证研究》,《中国会计与财务研究》第3期。

吴联生、王亚平(2003):《有效会计监管的均衡模型》,《经济研究》第6期。

谢德仁(2000):《会计信息的真实性与会计规则制定权合约安排》,《经济研究》第5期。

辛宇、黄欣怡、纪蓓蓓(2020):《投资者保护公益组织与股东诉讼在中国的实践——基于中证投服证券支持诉讼的多案例研究》,《管理世界》第1期。

薛澜、张帆(2016):《推广"双随机、一公开"机制完善监管改革》,《经济日报》2016年10月30日。

杨柏(2005):《上市公司信息披露违规行为监管博弈分析》,《管理世界》第8期。

叶建芳、周兰、李丹蒙、郭琳(2009):《管理层动机、会计政策选择与盈余管理——基于新会计准则下上市公司金融资产分类的实证研究》,《会计研究》第3期。

叶康涛、刘金洋(2021):《非财务信息与企业财务舞弊行为识别》,《会计研究》第9期。

叶钦华、叶凡、黄世忠(2022):《财务舞弊识别框架构建——基于会计信息系统论及大数据视角》,《会计研究》第3期。

于李胜(2007):《盈余管理动机、信息质量与政府监管》,《会计研究》第9期。

张蕊(2010):《高风险形式下企业欺诈与舞弊的防范》,《会计研究》第7期。

张新民、陈德球(2020):《移动互联网时代企业商业模式、价值共创与治理风险——基于瑞幸咖啡财务造假的案例分析》,《管理世界》第5期。

赵璨、王竹泉、杨德明、曹伟(2015):《企业迎合行为与政府补贴绩效研究——基于企业不同盈利状况的分析》,《中国工业经济》第7期。

中国知网 https://www.cnki.net

中国证监会(2015):《证监会2015年上半年稽查执法综述》,2015年。

中国证监会(2021):《证券期货违法行为行政处罚办法》,2021年。

周卫华、翟晓风、谭皓威(2022):《基于XGBoost的上市公司财务舞弊预测模型研究》,《数量经济技术经济研究》第7期。

朱锦余、高善生(2007):《上市公司舞弊性财务报告及其防范与监管——基于中国证券监督委员会处罚公告的分析》,《会计研究》第11期。

Albrecht, W. S.; Romney, Marshall B.; Cherrington, D. J.; Payne, I. R.; Roe, A. J. and Romney, M. B. "Red-Flagging Management Fraud: A Validation." *Advances in Accounting*, 1986, 3(3), pp. 323–333.

Bao, Y.; Ke, B.; Li, B.; Yu, Y. J. and Zhang, J. "Detecting Accounting Fraud in Publicly Traded U.S. Firms Using a Machine Learning Approach." *Journal of Accounting Research*, 2020, 58(1), pp. 199–235.

Beasley, M. S.; Carcello, J. V. and Hermanson, D. R. "Fraudulent Financial Reporting: 1987–1997: An Analysis of U.S. Public Companies." Committee of Sponsoring Organizations of the Treadway Commission, 1999.

Beasley, M. S.; Hermanson, D. R.; Carcello, J. V. and Neal, T. L. "Fraudulent Financial Reporting 1998–2007: An Analysis of U. S. Public Companies." Committee of Sponsoring Organizations of the Treadway Commission, 2010.

Bertomeu, J.; Cheynel, E.; Floyd, E. and Pan, W. "Using Machine Learning to Detect Misstatements." *Review of Accounting Studies*, 2021, 26(2), pp. 468–519.

Cao, N.; McGUINNESS, P. B. and Xi, C. "Does Securities Enforcement Improve Disclosure Quality? An Examination of Chinese Listed Companies' Restatement Activities." *Journal of Corporate Finance*, 2021, 67, pp. 1–30.

Cecchini, M.; Aytug, H.; Koehler, G. J. and Pathak, P. "Detecting Management Fraud in Public Companies." *Management Science*, 2010, 56(7), pp. 1146–1160.

Chen, D.; Jiang, D.; Liang, S. and Wang, F. "Selective Enforcement of Regulation." *China Journal of Accounting Research*, 2011, 4(1–2), pp. 9–27.

Chen, G.; Firth, M.; Gao, D. N. and Rui, O. M. "Is China's Securities Regulatory Agency a Toothless Tiger? Evidence from Enforcement Actions." *Journal of Accounting and Public Policy*, 2005, 24(6), pp. 451–488.

Christensen, H. B.; Liu, L. Y. and Maffett, M. "Proactive Financial Reporting Enforcement and Shareholder Wealth." *Journal of Accounting and Economics*, 2020, 69(2), p. 101267.

Davis, J. and Goadrich, M. "The Relationship between Precision-Recall and ROC Curves." Proceedings of the 23rd International Conference on Machine Learning – ICML'06, Pittsburgh, Pennsylvania: ACM Press, 2006.

Dechow, P. M.; Ge, W.; Larson, C. R. and Sloan, R. G. "Predicting Material Accounting Misstatements." *Contemporary Accounting Research*, 2011, 28(1), pp. 17–82.

Dechow, P. M.; Sloan, R. G. and Sweeney, A. P. "Detecting Earnings Management." *The Accounting Review*, 1995, 70(2), pp. 193–225.

DeFond, M. L. and Jiambalvo, J. "Debt Covenant Violation and Manipulation of Accruals." *Journal of Accounting and Economics*, 1994, 17(1–2), pp. 145–176.

中国知网 https://www.cnki.net

Geng, R.; Bose, I. and Chen, X. "Prediction of Financial Distress: An Empirical Study of Listed Chinese Companies Using Data Mining." *European Journal of Operational Research*, 2015, 241(1), pp. 236–247.

Graham, J. R.; Harvey, C. R. and Rajgopal, S. "The Economic Implications of Corporate Financial Reporting." *Journal of Accounting and Economics*, 2005, 40(1–3), pp. 3–73.

Gu, S.; Kelly, B. and Xiu, D. "Empirical Asset Pricing via Machine Learning." *The Review of Financial Studies*, 2020, 33(5), pp. 2223–2273.

Jones, J. J. "Earnings Management During Import Relief Investigations." *Journal of Accounting Research*, 1991, 29(2), pp. 193–228.

Ke, B. and Zhang, X. "Does Public Enforcement Work in Weak Investor Protection Countries? Evidence from China." *Contemporary Accounting Research*, 2021, 38(2), pp. 1231–1273.

Kothari, S. P.; Leone, A. J. and Wasley, C. E. "Performance Matched Discretionary Accrual Measures." *Journal of Accounting and Economics*, 2005, 39(1), pp. 163–197.

La Porta, R.; Lopez-De-Silanes, F. and Shleifer, A. "What Works in Securities Laws?" *The Journal of Finance*, 2006, 61(1), pp. 1–32.

La Porta, R.; Lopez-de-Silanes, F.; Shleifer, A. and Vishny, R. "Investor Protection and Corporate Governance." *Journal of Financial Economics*, 2000, 58(1–2), pp. 3–27.

Liu, C.; Chan, Y.; Alam Kazmi, S. H. and Fu, H. "Financial Fraud Detection Model: Based on Random Forest." *International Journal of Economics and Finance*, 2015, 7(7), pp. 178–188.

Perols, J. "Financial Statement Fraud Detection: An Analysis of Statistical and Machine Learning Algorithms." *AUDITING: A Journal of Practice & Theory*, 2011, 30(2), pp. 19–50.

Perols, J. L.; Bowen, R. M.; Zimmermann, C. and Samba, B. "Finding Needles in a Haystack: Using Data Analytics to Improve Fraud Prediction." *The Accounting Review*, 2017, 92(2), pp. 221–245.

Persons, O. S. "Using Financial Statement Data To Identify Factors Associated With Fraudulent Financial Reporting." *Journal of Applied Business Research*, 1995, 11(3), pp. 38–46.

Phillips, J.; Pincus, M. and Rego, S. O. "Earnings Management: New Evidence Based on Deferred Tax Expense." *The Accounting Review*, 2003, 78(2), pp. 491–521.

Posner, R. A. "An Economic Approach to Legal Procedure and Judicial Administration." *The Journal of Legal Studies*, 1973, 2(2), pp. 399–458.

Securities and Exchange Commission. *Spotlight on Financial Reporting and Audit (FRAud) Group, 2020.* https://www.sec.gov/spotlight/financial-reporting-and-audit-task-force.shtml.

Shleifer, A. and Wolfenzon, D. "Investor Protection and Equity Markets." *Journal of Financial Economics*, 2002, 66(1), pp. 3–27.

Wang, Y.; Wang, L.; Li, Y.; He, D.; Liu, T. Y. and Chen, W. "A Theoretical Analysis of NDCG Ranking Measures." Proceedings of the 26th Annual Conference on Learning Theory, New York: PMLR, 2013.

Wolpert, D. H. "The Lack of A Priori Distinctions Between Learning Algorithms." *Neural Computation*, 1996, 8(7), pp. 1341–1390.

中国知网 https://www.cnki.net

附　录

附表A　　会计比率[@14]定义

序号	会计比率	指标定义
1	营运资本应计项变动率	营运资本变动值/平均总资产,其中,营运资本=(流动资产合计-货币资金-交易性金融资产)-(流动负债合计-一年内到期的非流动负债-应交税费)
2	RSST应计项变动率	(经营资本变动值+非现金净营运资产变动值+金融资产变动值)/平均总资产,其中,非现金净营运资产=(资产合计-流动资产合计-可供出售金融资产-持有至到期投资-长期股权投资)-(负债合计-流动负债合计-长期借款-应付债券);金融资产=(交易性金融资产+可供出售金融资产+持有至到期投资+长期股权投资)-(长期借款+应付债券+一年内到期的非流动负债+优先股)
3	应收账款变动率	Δ应收账款/平均总资产
4	存货变动率	Δ存货/平均总资产
5	无形资产比例	(资产总计-固定资产-在建工程-工程物资-货币资金)/资产总计
6	现金销售变动率	(现金销售t-现金销售t_{-1})/现金销售t_{-1},其中,现金销售=营业收入-Δ应收账款
7	现金保证金变动率	(现金保证金t-现金保证金t_{-1})/现金保证金t_{-1},其中,现金保证金=1-[(营业成本-Δ存货+Δ应付账款)/(营业收入-Δ应收账款)]
8	ROA变动率	(净利润/平均总资产)t-(净利润/平均总资产)t_{-1}
9	自由现金流变动率	Δ(营业利润-RSST应计项)/平均总资产
10	是否再融资	存在股权或者债券融资,为1,否则为0
11	账面市值比	所有者权益合计/市值
12	折旧率指数	上期折旧率/本期折旧率,其中,折旧率=折旧费用/固定资产原值
13	留存收益比例	(盈余公积+未分配利润)/资产总计
14	息税前利润比例	(净利润+财务费用+所得税费用)/资产总计

附表B　　2013-2018年会计更正频率前40科目

序号	会计更正科目	会计更正次数	是否属于会计科目[@33]
1	未分配利润	328	√
2	净利润	274	√
3	归属于母公司所有者的净利润	219	
4	营业成本	200	√
5	减:所得税费用	191	√
6	营业收入	174	√

中国知网　https://www.cnki.net

（续表）

序号	会计更正科目	会计更正次数	是否属于会计科目[@33]
7	资产减值损失	170	
8	利润总额	163	
9	归属母公司股东权益合计	155	
10	所有者权益(或股东权益)合计	153	√
11	资产总计	150	√
12	应交税费	141	√
13	递延所得税资产	133	
14	其他应收款	121	
15	其他应付款	118	
16	应收账款	116	√
17	存货	116	√
18	盈余公积	105	√
19	负债合计	103	√
20	营业利润	101	√
21	负债和所有者权益(或股东权益)总计	100	
22	管理费用	97	
23	预付款项	94	
24	财务费用	91	√
25	少数股东权益	84	
26	应付账款	77	√
27	销售费用	74	
28	基本每股收益	74	
29	预收款项	67	
30	少数股东损益	64	
31	稀释每股收益	61	
32	其他流动资产	59	
33	归属于母公司所有者的综合收益总额	59	
34	综合收益总额	58	
35	流动资产合计	58	√
36	营业税金及附加	56	
37	非流动资产合计	54	
38	减:营业外支出	52	
39	流动负债合计	51	√
40	固定资产	49	√

说明:根据巨潮资讯网数据统计。

中国知网 https://www.cnki.net

附表C　　2013-2018年机器学习滚动预测PRC和NDCG@k

Panel A:机器学习滚动预测PRC

预测因子	预测年份	LASSO-Logit	SVM	RUSBoost	XGBoost	Random Forest	LightGBM	TabNet	NODE
会计比率[@14]	2013	0.0522	0.0426	0.0386	0.0466	0.0440	0.0694	0.0434	0.0395
	2014	0.0842	0.0644	0.0536	0.0500	0.0602	0.0520	0.0434	0.0719
	2015	0.0590	0.0674	0.0716	0.0568	0.0706	0.0524	0.0481	0.0552
	2016	0.0751	0.0677	0.0829	0.0805	0.0790	0.0848	0.0774	0.0677
	2017	0.0913	0.0932	0.1176	0.1189	0.1126	0.1219	0.0748	0.0840
	2018	0.1073	0.1044	0.1042	0.1403	0.1356	0.1423	0.1034	0.1328
会计科目[@33]	2013	0.0435	0.0326	0.0956	0.1084	0.1003	0.0831	0.0305	0.0344
	2014	0.0663	0.0485	0.0606	0.0815	0.0763	0.0832	0.0469	0.0502
	2015	0.0580	0.0633	0.0665	0.0715	0.0738	0.0811	0.0564	0.0556
	2016	0.0834	0.0843	0.0886	0.0965	0.0871	0.0884	0.0610	0.0611
	2017	0.1017	0.0841	0.1257	0.1373	0.1400	0.1180	0.0842	0.0738
	2018	0.1410	0.0893	0.1097	0.1339	0.1400	0.1261	0.0746	0.1181
会计科目[@331]	2013	0.0570	0.0403	0.1095	0.1063	0.1038	0.0671	0.0360	0.0378
	2014	0.0637	0.0533	0.0736	0.0927	0.0845	0.0935	0.0417	0.0582
	2015	0.0758	0.0573	0.0681	0.0757	0.0891	0.0842	0.0565	0.0695
	2016	0.1071	0.0794	0.0831	0.1089	0.0822	0.1012	0.0720	0.0735
	2017	0.1302	0.1190	0.1528	0.1655	0.1388	0.1320	0.0842	0.0858
	2018	0.1239	0.1049	0.1130	0.1823	0.1427	0.1478	0.1475	0.1264

Panel B:机器学习滚动预测NDCG@k

预测因子	预测年份	LASSO-Logit	SVM	RUSBoost	XGBoost	Random Forest	LightGBM	TabNet	NODE
会计比率[@14]	2013	0.1589	0.1144	0.1001	0.1258	0.0840	0.2043	0.1248	0.0801
	2014	0.2019	0.1275	0.1160	0.0756	0.1130	0.1008	0.0817	0.1376
	2015	0.0793	0.1057	0.1106	0.0765	0.0934	0.0829	0.0448	0.0708
	2016	0.1020	0.0785	0.0840	0.1148	0.0889	0.0915	0.1066	0.0781
	2017	0.1390	0.1307	0.1456	0.1737	0.1454	0.1701	0.0746	0.1171
	2018	0.1518	0.1195	0.1496	0.1802	0.1479	0.1914	0.1344	0.2176
会计科目[@33]	2013	0.1200	0.0723	0.2145	0.2660	0.2642	0.2278	0.0428	0.0949
	2014	0.1424	0.0838	0.1237	0.1712	0.1507	0.1471	0.0584	0.0887
	2015	0.1041	0.1052	0.1152	0.1346	0.0946	0.1468	0.0714	0.1089
	2016	0.1368	0.1112	0.1290	0.1391	0.1171	0.1147	0.0444	0.0921
	2017	0.1492	0.1182	0.1886	0.2267	0.2005	0.1836	0.1109	0.1136
	2018	0.1591	0.1326	0.1694	0.1844	0.1913	0.1802	0.0536	0.2205

中国知网　https://www.cnki.net

（续表）

Panel B：机器学习滚动预测 NDCG@k

预测因子	预测年份	LASSO-Logit	SVM	RUSBoost	XGBoost	Random Forest	LightGBM	TabNet	NODE
会计科目[@331]	2013	0.1464	0.0845	0.2870	0.2544	0.2564	0.1852	0.1105	0.0684
	2014	0.1133	0.1346	0.1426	0.1917	0.1452	0.1987	0.0560	0.1069
	2015	0.1499	0.0751	0.1118	0.1522	0.1659	0.1479	0.0579	0.1185
	2016	0.1474	0.0692	0.1172	0.1490	0.0823	0.1386	0.0807	0.0760
	2017	0.1636	0.1367	0.2116	0.2164	0.1846	0.1645	0.0776	0.0984
	2018	0.1838	0.1509	0.1472	0.2658	0.1906	0.1816	0.2318	0.1491

Machine Learning and Accounting Fraud: A Predictive Perspective Based on Non-selection Factors

Zhou Wei; Wang Song; Xu Yude; Shen Feng

Abstract: This paper explores the theoretical and practical implications of applying machine learning to capital market regulation, aiming to enhance the governance of accounting fraud. Using accounting fraud data from China's capital market between 1998 and 2021, the study employs eight mainstream machine learning models to assess the strengths and potential of machine learning in curbing accounting fraud, focusing on a non-selection factor perspective. The study finds that using machine learning to predict accounting fraud does not rely on the pre-selection of factors, with prediction performance surpassing various combinations of pre-selected accounting indicators, showing an average AUC improvement of 12.22%. The analysis suggests that this is related to the fact that pre-selected indicators are more susceptible to targeted avoidance behaviors by the market. A subsequent study discusses the potential of machine learning for optimising the "Dual random selections plus timely release of results" inspection policy in China's capital market. The introduction of machine learning can significantly increase the detection of accounting fraud, lower the threshold for discovering major fraud cases, and shorten the time delay in penalty, thus curbing the spread of accounting fraud.

Key words: accounting fraud, machine learning, non-selection factors, accounting ratios

JEL codes: C53, H83, M41

（截稿：2024年8月　责任编辑：宋志刚）

中国知网 https://www.cnki.net